



UNIVERSITÉ DE TUNIS EL MANAR  
FACULTÉ DES SCIENCES DE TUNIS

---

# MÉMOIRE DE MASTÈRE

présenté en vue de l'obtention du  
**Diplôme de Mastère en Informatique**

par

**Aymen SELLAOUTI**

(Maîtrise en Informatique, FST)

## **Intégration des informations et des connaissances structurelles dans la classification des images satellitaires forestières haute résolution**

soutenu le 17 Janvier 2009, devant le jury d'examen

MM. **Khaled BSAIES**  
**Sadok BEN YAHIA**  
**Atef HAMOUDA**

*Président*  
*Membre*  
*Directeur du mémoire*





## *Dédicaces*

*Je voudrais tout d'abord remercier infiniment dieu.*

*En témoignage de ma gratitude, de mon amour et de ma grande reconnaissance, je dédie ce travail à :*

*Ma mère Nebiha que je remercie pour son amour, sa patience et sa confiance en moi.*

*Mon père Abderrahmen pour son soutien illimité et pour la confiance qu'il a mis en moi.*

*L'âme de mon grand père Ahmed et de ma grand mère Chedlia.*

*Mes chers grands parents Hbibba et Romdhane.*

*Ma sœur Monia.*

*Toute la famille Sellaouti.*

*Toute la famille Tamarzist.*

*Mes amis Ahmed, Bassem, Ghassen, Mehdi, Nidhal, Rami, Boutheina, Jihen, Manel, Myriam, Samia et Saoussen.*

*Tous mes professeurs et à toutes les personnes qui ont fait de moi ce que je suis maintenant.*

*Tous mes amis et les gens que j'aime.*

## Remerciements

*Je voudrais d'abord remercier Mr. Khaled BSAIES, Professeur à la FST, pour l'honneur qu'il me fait en présidant ce jury.*

*Je remercie également Mr. Sadoûk BEN YAHIA, Maître-assistant habilité à la FST, d'avoir bien voulu participer à ce jury et juger mon travail.*

*Je tiens à adresser mes vifs remerciements et ma profonde reconnaissance à Mr. Atef HAMOUDA, Maître-assistant habilité à la FST, pour avoir dirigé mon travail, pour son assistance et sa disponibilité, enfin et surtout pour ses encouragements et son soutien. L'intérêt qu'il a manifesté pour mon travail, ses suggestions et ses remarques ont été d'une importance capitale.*

*Je remercie aussi Melle Zouhour BEN DHIAF, Assistante à la FST pour son assistance et sa disponibilité, ses encouragements, son soutien et surtout pour ces remarques et ces directives qui m'ont énormément aidé et qui ont contribué au bon déroulement de ce Mastère.*

*Je remercie aussi Mr Mohamed NAOUAI, Assistant à la FST pour son aide et son encouragement continu.*

*Je remercie aussi Mme Ines ELOUADI pour son aide et son encouragement continu.*

*Je remercie aussi tout le personnel de l'AFA pour leur aide et leurs soutiens continus et plus particulièrement Mr Habib AZAIEZ, Mr Lotfi BELHAJ, Mr Slim ZOUAOUI, Mr Mehrez HANNAFI et Mr Imed LAHIANI.*

*Mes remerciements et ma gratitude vont enfin au personnel du Département des Sciences de l'Informatique de la FST.*

*Je voudrais finalement adresser ma sincère reconnaissance à tous ceux qui m'ont aidé par leur compréhension et leur soutien.*

# Table des matières

<b>Introduction générale</b>	<b>1</b>
<b>1 État de l’art</b>	<b>5</b>
1.1 Introduction . . . . .	6
1.2 Les images de télédétection . . . . .	6
1.2.1 Système d’acquisition . . . . .	7
1.2.2 Résolution des images de télédétection . . . . .	8
1.2.3 Domaines d’application . . . . .	9
1.3 Classification . . . . .	10
1.3.1 Définition . . . . .	10
1.3.2 Classification supervisée . . . . .	10
1.3.3 Classification non supervisée . . . . .	11
1.3.4 Les classifieurs . . . . .	11
1.3.5 Approche spectrale . . . . .	13
1.3.6 Approche texturale . . . . .	13
1.3.7 Approche floue . . . . .	16
1.3.8 Approche contextuelle . . . . .	17
1.3.9 Approche multi-sources . . . . .	18
1.3.10 Approche structurelle . . . . .	19
1.3.11 Classification hybride . . . . .	20
1.4 Conclusion . . . . .	20
<b>2 Classification structurelle</b>	<b>23</b>
2.1 Introduction . . . . .	24
2.2 Informations et connaissances structurelles . . . . .	24
2.2.1 Informations structurelles . . . . .	24

2.2.2	Connaissances structurelles . . . . .	24
2.3	Mesures et indices de formes . . . . .	25
2.3.1	Mesures . . . . .	25
2.3.2	Les indices de formes . . . . .	25
2.4	Les relations spatiales . . . . .	30
2.5	Approches de classification structurelle . . . . .	31
2.5.1	Classification structurelle basée sur une approche par régions	31
2.5.2	Approche par mise en correspondance des graphes . . . . .	33
2.5.3	Approche par Modification de Régions (AMR) . . . . .	36
2.5.4	Approche par sur-segmentation . . . . .	38
2.5.5	Approche par modification des degrés d'appartenance dans une partition floue . . . . .	40
2.6	Conclusion . . . . .	42
<b>3</b>	<b>Identification des formations forestières à partir des images haute résolution</b>	<b>43</b>
3.1	Introduction . . . . .	44
3.2	Segmentation par région . . . . .	44
3.2.1	Définition . . . . .	44
3.2.2	Algorithmes de segmentation par région . . . . .	45
3.3	Extraction des couronnes d'arbres . . . . .	48
3.3.1	Approche par maximums locaux . . . . .	48
3.3.2	Approche contour . . . . .	49
3.3.3	Approche Région . . . . .	51
3.3.4	Approche Objet . . . . .	53
3.4	Bilan et comparaison . . . . .	57
3.5	Conclusion . . . . .	60
<b>4</b>	<b>Système de classification basé sur l'intégration des informations et des connaissances structurelles</b>	<b>61</b>
4.1	Introduction . . . . .	62
4.2	Architecture du système . . . . .	62
4.3	Extraction des couronnes d'arbres . . . . .	63
4.3.1	Choix de l'algorithme de segmentation . . . . .	64

4.3.2	Croissance de région par mouvement brownien . . . . .	67
4.3.3	Automatisation des paramètres de l'algorithme . . . . .	68
4.4	Caractérisation des régions . . . . .	70
4.4.1	La texture . . . . .	70
4.4.2	Mesures et Indices de formes . . . . .	73
4.5	Apprentissage automatique supervisé . . . . .	74
4.6	Classification des images . . . . .	75
4.6.1	Classifieur par maximum de vraisemblance . . . . .	76
4.6.2	Intégration de l'information et des connaissances structurelles	77
4.7	Conclusion . . . . .	81
<b>5</b>	<b>Expérimentation et évaluation</b>	<b>83</b>
5.1	Introduction . . . . .	84
5.2	Présentation de l'image . . . . .	84
5.3	Croissance de région par mouvement Brownien . . . . .	85
5.3.1	Paramétrisation de l'algorithme . . . . .	85
5.3.2	Extraction des couronnes d'arbres . . . . .	89
5.4	Apprentissage . . . . .	93
5.5	Caractérisation des régions . . . . .	94
5.6	Validation de la classification . . . . .	95
5.7	L'apport des connaissances structurelles dans la classification . . .	97
5.8	Conclusion . . . . .	100
	<b>Conclusion et perspectives</b>	<b>101</b>





# Table des figures

1.1	Fonctionnement des différents types de capteurs . . . . .	7
1.2	Exemple d'application de l'algorithme K-plus proches voisins . . .	12
1.3	Représentation des SVM . . . . .	13
1.4	Exemples de texture aléatoire . . . . .	14
1.5	Exemples de texture périodique . . . . .	15
1.6	Processus de classification : sujets frontières . . . . .	16
1.7	Processus de déffuzification . . . . .	17
1.8	Classification multi sources . . . . .	18
2.1	Exemple de graphe de référence modèle : Représentation parties anatomiques du cerveau humain . . . . .	35
2.2	Mise en correspondance entre un graphe aléatoire et un graphe de référence . . . . .	36
2.3	Vue d'ensemble du système de classification utilisant des connaissances expertes . . . . .	37
2.4	Vue d'ensemble du système AMR . . . . .	38
2.5	Exemples conceptuels de qualité de segmentations préliminaires : .	39
2.6	Exemples conceptuels de l'approche par sur-segmentation : . . . .	40
2.7	Schéma conceptuel de l'approche par modification des degrés d'appartenance dans une partition floue . . . . .	41
3.1	Représentation d'une image sous forme de terrain 3D et remplissage des bassins avec de l'eau . . . . .	47
3.2	Ligne de partage des eaux entre 2 bassins . . . . .	47

3.3	Vue tridimensionnelle d'une petite partie (16*20 pixels) représentant les cimes plus brillantes comme des montagnes souvent séparées par des vallées d'ombre . . . . .	49
3.4	Extrait d'une carte topographique 3D d'une portion de forêt . . .	50
3.5	Résultat de l'exécution de l'algorithme de " suivi des vallées " . .	51
3.6	Croissance de région par mouvement Brownien . . . . .	53
3.7	Approche objets : différentes formes de patrons . . . . .	54
3.8	Prise de vue des photographies aériennes et point Nadir : projeté orthogonal sur le sol de la caméra . . . . .	55
3.9	Ellipse et sa frontière . . . . .	55
3.10	Extrait d'une plantation de peupliers . . . . .	56
3.11	Extraction des arbres dans des zones denses . . . . .	58
3.12	Extraction des couronnes d'arbres dans des zones éparses . . . . .	59
4.1	Architecture du système . . . . .	64
4.2	Segmentation d'un groupement d'arbres dense . . . . .	67
4.3	Segmentation d'un groupement d'arbres éparses . . . . .	67
4.4	Fonctionnement de l'algorithme de croissance de régions par mouvement brownien . . . . .	68
4.5	Matrice de cooccurrence . . . . .	71
4.6	Illustration du contraste sur deux textures de Brodatz différentes	72
4.7	Illustration de l'entropie . . . . .	72
4.8	Illustration de l'homogénéité . . . . .	73
4.9	Diamètre de Ferret . . . . .	74
4.10	L'apprentissage supervisé . . . . .	74
4.11	Intégration de l'information structurelle dans le vecteur Caractéristique	78
4.12	Intégration de la connaissance structurelle dans le système . . . .	79
4.13	Image contenant une frontière entre deux groupements d'arbres .	80
5.1	Images satellitaires haute résolution : Forêt de Jendouba . . . . .	85
5.2	Extraction des maximums locaux pour une forêt éparses . . . . .	86
5.3	Extraction des maximums locaux pour une forêt dense . . . . .	87
5.4	Résultats de segmentation avec l'algorithme de croissance de régions par mouvement Brownien avec deux seuils différents : . . . . .	88

5.5	Segmentation avec deux nombre de pas différents . . . . .	89
5.6	Segmentation d'un groupement de chêne zen dense . . . . .	90
5.7	Segmentation d'un groupement de chêne zen épars . . . . .	91
5.8	Segmentation d'un groupement de chêne liège . . . . .	91
5.9	Segmentation d'un groupement d'arboretum . . . . .	92
5.10	Segmentation d'un groupement de forêt résineux . . . . .	92
5.11	Inventaire forestier . . . . .	93
5.12	Inventaire forestier superposé sur l'image . . . . .	94
5.13	Courbe représentant l'évolution de la classification en fonction des caractéristiques structurelle . . . . .	95
5.14	Classification d'une zone mixte . . . . .	98
5.15	Groupement de forêt chênes liège classé en intégrant les informa- tions structurelles . . . . .	99
5.16	Groupement de forêt chênes liège classé en intégrant les connais- sances structurelles . . . . .	99



# Introduction générale

La classification spectrale est l'une des premières approches de classification d'images. Elle consiste à regrouper les pixels similaires sur le plan radiométrique et se base donc sur le niveau de gris comme seul attribut du système d'affectation. Quoi qu'elle permette d'offrir dans certains cas un résultat qui reflète de manière fidèle la réalité du terrain étudié, elle reste tributaire d'une conformité, d'une répartition homogène des classes recensées et d'une bonne stabilité radiométrique des zones d'apprentissage. C'est ainsi que d'autres approches ont été proposées afin d'enrichir le système de classification par des données additives ou des connaissances expertes dans le but de converger vers de meilleurs résultats. Une des premières approches proposées pour remédier au problème de l'insuffisance de l'information radiométrique vise à introduire l'information de texture. Cette information intègre une nouvelle notion dans le processus de classification qui se réfère à l'arrangement spatial entre les pixels. En effet, la texture décrit à travers des primitives les propriétés caractéristiques de l'image et la dépendance spatiale entre ses pixels.

Une autre approche, visant à introduire les notions de la logique floue dans la classification, a été proposée afin de contourner une contrainte très gênante de la classification spectrale, qui consiste en l'exclusivité de l'assignation d'un pixel à une classe.

La classification multi-sources qui se base sur l'utilisation de diverses sources de données est l'une des approches introduites en classification d'images de télédétection pour résoudre le problème de confusion entre classes d'occupation du sol. En effet, l'intégration d'informations multi-capteurs, de données multi-temporelles, de données exogènes telles que le modèle numérique de terrain ou la carte géologique permet de caractériser au mieux les classes et de dépasser l'ambiguïté de l'information radiométrique.

Malgré l'abondance des techniques de classification et la diversité des approches qui visent à fournir une cartographie de l'occupation du sol à partir des images satellites, des problèmes persistent pour départager des classes qui ont des caractéristiques radiométriques et texturales assez proches et pour lesquelles nous ne disposons pas d'information issues d'autres sources. Toutefois, l'analyse visuelle réalisée par un expert du terrain arrive à distinguer entre ces classes confuses et ce à travers les connaissances structurelles dont il dispose. C'est ainsi que le photo interprète humain s'appuie sur la forme géométrique des régions, leur étendue ainsi que les relations spatiales qui les relient afin de déduire les formations terrestres et les espèces.

Ainsi, nous nous proposons dans le cadre de ce travail d'utiliser l'information structurelle et de l'impliquer dans le processus de classification des images de télédétection.

L'estimation des caractéristiques structurelles s'effectue après une première phase d'extraction des régions. La classification se fait alors en se basant sur ces caractéristiques.

La classification par région peut s'effectuer relativement à trois approches :

- ) L'approche par mise en correspondance est basée sur l'appariement de deux graphes dont un représente la scène à analyser et l'autre le modèle de référence. Les caractéristiques structurelles sont introduites comme attributs dans les nœuds et les arcs des graphes.
- ) L'approche par sur-segmentation qui utilise les connaissances structurelles pour " recoller " les segments obtenus après une première phase de sur segmentation.
- ) L'approche par modification des régions innove en intégrant les connaissances structurelles pixel par pixel.

Dans le cadre de ce mastère, nous nous sommes concentrés sur les images de la forêt et plus particulièrement à la classification des images forestière à l'arbre près. Bien que plusieurs études aient été menées dans ce domaine, à notre connaissance, aucune d'entre elles ne s'est intéressée aux informations structurelles.

Étant donné que les informations et les connaissances structurelles ne peuvent pas être intégrées pixel par pixel, nous avons procédé à une étape de segmentation qui nous permet d'extraire les régions de l'image et donc d'extraire les couronnes d'arbre. Se pose alors le problème des informations et des connaissances à

fournir au système. La structure des parcelles ou des couronnes d'arbres appartenant à des espèces différentes doit être évaluée à travers des mesures numériques afin qu'elle puisse être intégrée dans le processus de classification de l'image de télédétection. En l'absence de connaissances concernant la forme des couronnes, nous avons mis en évidence la forme des régions en se basant sur des informations structurelles illustrées par les indices de formes. Ces paramètres de structure dégagés à partir des couronnes identifiées sont utilisés dans des algorithmes de classification afin d'affecter chaque couronne à une classe de l'échantillon fixé dans la phase d'apprentissage. Les connaissances concernant les indices de formes sont quant à elle introduites après une classification initiale.

La structure du présent rapport est la suivante :

### **Chapitre 1**

Ce chapitre présente les caractéristiques des images de télédétection ainsi qu'un état de l'art des méthodes de classification d'images.

### **Chapitre 2**

Ce chapitre introduit la classification structurelle en présentant la définition des informations et des connaissances structurelles. Nous présentons ici les indices de formes et les mesures qui constituent la base de la caractérisation de la forme des régions. Nous exposons aussi les différentes approches de la classification structurelle.

### **Chapitre 3**

Les informations et les connaissances structurelles ne peuvent pas être intégrées pixel par pixel d'où la nécessité d'une segmentation de l'image en régions. Etant donné le cadre particulier de notre travail qui opère sur des images forestières de télédétection, nous nous intéressons dans ce chapitre à la segmentation par région et plus particulièrement à l'extraction des couronnes d'arbres.

### **Chapitre 4**

Dans ce chapitre, nous présentons l'architecture d'un système de classification s'appuyant sur les informations et les connaissances structurelles. Nous présentons

l'algorithme de croissance de région par mouvement brownien qui fait ressortir les couronnes d'arbres à classer. Nous présentons ensuite le modèle de donnée ainsi que le classifieur retenu.

## **Chapitre 5**

Dans ce chapitre, nous présentons les résultats de nos expérimentations sur une image QuickBird représentant la zone d'Ain Drahim gouvernorat de Jendouba. L'apport des informations et des connaissances structurelles est illustré à travers la synthèse des résultats avant et après leur introduction.



# Chapitre 1

## État de l'art

## 1.1 Introduction

Dans ce premier chapitre, nous présentons tout d'abord les caractéristiques des images de télédétection en présentant en premier lieu leur système d'acquisition. Nous nous intéressons ensuite à leur résolution pour finalement présenter leur domaine d'application.

Nous introduisons ensuite les travaux de classifications d'images existants réalisés qui sont :

- La classification spectrale
- La classification texturale
- La classification multi-sources
- La classification contextuelle
- La classification floue
- La classification structurelle

## 1.2 Les images de télédétection

La télédétection est l'ensemble des connaissances et techniques utilisées pour déterminer des caractéristiques physiques et biologiques d'objets par des mesures effectuées à distance, sans contact matériel avec ceux-ci.

La télédétection est donc la technique qui, par l'acquisition d'images, permet d'obtenir de l'information sur la surface de la Terre sans contact direct avec celle-ci.

Dans la plupart des cas, la télédétection implique une interaction entre l'énergie incidente et les cibles. D'où le besoin d'avoir des moyens d'acquisition de l'information.

### 1.2.1 Système d'acquisition

Les capteurs sont la source principale de l'acquisition des images de télédétection. En effet, les capteurs sont les instruments qui permettent de transformer le rayonnement électromagnétique en informations perceptibles et analysables par l'œil humain, en l'occurrence l'image.

Les capteurs permettent d'acquérir les données concernant les objets étudiés dans une bande donnée de longueur d'onde. Nous distinguons deux types de capteurs :

- Les capteurs actifs sont à la fois émetteurs et récepteurs, ils produisent donc leurs propres énergies pour illuminer la cible. En effet, ils dégagent un rayonnement électromagnétique qui est dirigé vers la cible. Le rayonnement réfléchi par la cible est alors perçu et mesuré par les capteurs. Les radars et les lasers sont les capteurs actifs les plus connus.
- Les capteurs passifs sont uniquement récepteurs, ils ont donc besoin d'une source d'énergie externe pour illuminer la cible. Nous pouvons citer le radiomètre ou les caméras. La source d'énergie est le plus souvent le soleil.




FIGURE 1.1 – Fonctionnement des différents types de capteurs

Comme nous l'avons déjà évoqué, les capteurs peuvent être placés dans différentes plateformes, mais la plateforme la plus utilisée reste sans conteste les satellites. Certaines caractéristiques propres aux satellites en font des instruments particulièrement utiles pour l'acquisition d'information sur la surface de la Terre.

Nous distinguons plusieurs types de satellites :

- **les satellites météorologiques** : Ils servent à la prédiction et à la surveillance

de la météo.

- **Les satellites d'observation marine :** Ils servent par exemple à observer la couleur et la température de l'océan, particulièrement dans les régions côtières. La résolution spatiale et spectrale permettait de détecter les polluants dans les couches supérieures de l'océan et de déterminer la nature des matériaux en suspension dans la colonne d'eau.
- **Les satellites d'observation de la terre :** Ils sont les plus connues. En effet, ils permettent une cartographie détaillée de la surface de la terre. Le système SPOT est l'un des systèmes les plus connus, c'est une série de satellites d'observation de la Terre qui ont été conçus et lancés par le Centre National d'Études Spatiales. Ce système nous permet maintenant d'acquérir des images satellitaires de très hautes résolutions atteignant les 50cm/pixel.

### 1.2.2 Résolution des images de télédétection

Nous distinguons trois types de résolution pour les images de télédétection :

- La résolution spatiale d'une image numérique représente la plus petite distance permettant de discriminer deux objets voisins, c'est la surface du sol que représente un pixel. Elle diffère d'un satellite à un autre.
- La résolution spectrale décrit la capacité d'un capteur à utiliser de petites fenêtres de longueurs d'onde. Plus la résolution spectrale est fine, plus les fenêtres des différents canaux du capteur sont étroites.
- La résolution radiométrique représente la sensibilité à l'intensité de l'énergie électromagnétique de l'image. La résolution radiométrique d'un système de télédétection décrit sa capacité de reconnaître de petites différences dans l'énergie électromagnétique. Plus la résolution radiométrique d'un capteur est fine, plus le capteur est sensible à de petites différences dans l'intensité de l'énergie reçue. La gamme de longueurs d'onde à l'intérieur de laquelle un capteur est sensible se nomme plage dynamique.

Domaines	Applications
Milieu marin et littoral	Qualité de l'eau, circulation océanique, végétation marine
Atmosphère et climat	Météorologie, bilans énergétiques et hydriques
Hydrologie	Comportement de l'eau à la surface du sol et dans le sol, cycles de l'eau
Glaciologie	Suivi des glaciers
Biosphère	Cartographie de la végétation
Espace aménagé	Statistiques agricoles, foresterie, croissance des villes
Archéologie	Cartographie des sites archéologiques
Humanitaire	Pré-alerte de famine, réfugiés (camps)
Santé	Prévision des épidémies
Catastrophes environnementales	Feux de forêts, innodations, sécheresses, marées noires, etc.
Changements globaux	Désertification, variation climatique, composition de l'atmosphère

TABLE 1.1 – Domaines d'application des images de la télédétection

### 1.2.3 Domaines d'application

Les images de télédétection sont utilisées dans plusieurs domaines. Leur premier grand domaine d'application a été l'étude de l'atmosphère (météorologie et climatologie). L'intérêt dans ce domaine est d'assurer une couverture globale et très fréquemment répétée de la planète entière. Nous citons la détection des réseaux routiers, la cartographie des végétations et la prévention des feux de bois. Nous vous présentons quelques domaines d'applications des images de télédétection dans le tableau 1.1.

## 1.3 Classification

### 1.3.1 Définition

Dans le dictionnaire, la définition du mot classification est la suivante :

” Une classification est le classement hiérarchique en catégories selon des critères précis ”. La classification est donc le processus qui permet d’affecter un ensemble d’individus à classer selon un ensemble de critère.

Une classification est donc une partition de l’ensemble des pixels  $D$  de l’image en ensembles  $(C_i)_{i=1..K}$  (classes) tels que (1.1) :

$$\forall i, \forall j \in \{1, \dots, K\}, i \neq j \Rightarrow C_i \cap C_j = \emptyset \text{ et } \bigcup_{i=1}^k C_i = D \quad (1.1)$$

Plusieurs approches de classification d’images ont été citées dans la littérature, et plusieurs tentatives ont été effectuées pour essayer d’améliorer de plus en plus le processus de classification en intégrant de nouvelles informations et paramètres qui peuvent y contribuer.

### 1.3.2 Classification supervisée

Il s’agit d’une technique très courante fondée sur l’analyse statistique d’échantillons. Cette classification demande à l’utilisateur d’instruire le système en désignant des zones de l’image comme étant des échantillons représentatifs des classes à extraire. La classification est donc précédée d’une phase d’apprentissage.

Les fondements de l’apprentissage automatique sont les mathématiques et la théorie des probabilités.

Une étape très importante dans le processus de classification est celle du choix du classifieur. En effet, le choix du classifieur pèse dans le résultat de la classification. Parmi les classifieurs les plus utilisés nous pouvons citer le ”classifieur par le maximum de vraisemblance” et le ”classifieur par la distance minimale” [21][46]. Nous pouvons aussi citer le ”classifieur par arbre de décision binaire” [47], le ”classifieur par K plus proches voisins” [2][14], les ”C-moyennes nettes” [11] et le classifieur bayésien sont aussi d’autres exemples de classifieurs classiques et largement évoqués dans la littérature [21].

### 1.3.3 Classification non supervisée

La classification non supervisée ne demande aucune connaissance a priori. Cette méthode est souvent utilisée dans le cas où aucune information préliminaire n'est disponible sur les objets à classer. Deux cas peuvent se présenter : il existe déjà des classes qui sont définies indépendamment de l'image et donc sans passer par un apprentissage, ou le nombre de classes et les caractéristiques qui leurs sont associées sont définies automatiquement lors de la classification elle-même.

Le principe de la classification non supervisée consiste donc à regrouper les pixels selon la similarité de leurs caractéristiques, à déterminer la signature de chacune des classes constituées, et à en rechercher la signification.

La classification non supervisée peut être divisée en deux grandes familles. La classification hiérarchique et la classification par partitionnement [41].

Des exemples de classification non supervisée sont : la méthode de la nuée dynamique [20], la méthode hiérarchique ascendante et la méthode des centres mobiles [28].

### 1.3.4 Les classifieurs

Un classifieur est un processus qui utilise l'information issue de l'apprentissage pour attribuer à chaque point ou région de l'image une catégorie ou une classe.

Le choix du classifieur est très important dans le processus de classification. Il permet d'optimiser les séparations ou les frontières de décisions entre les régions caractéristiques des classes.

**Le classifieur par maximum de vraisemblance** C'est l'un des classifieur les plus utilisés dans la littérature [46], ce classifieur assigne chaque pixel ou région à la classe qui donne le degré de vraisemblance maximale, il est calculé à partir des statistiques des échantillons. Le degré de vraisemblance est la probabilité conditionnelle qu'un pixel ou une région appartiennent à chacune des classes calculées.

**Classifieur par K-plus proches voisins** Ce classifieur a été développé par Fix et Hodger en 1951 [2][14][26]. Son but est d'associer chaque pixel de l'image à la classe qui est majoritaire parmi ces classes voisines. Comme illustré dans

la figure 1.2, nous regardons la classe des  $k=5$  voisins les plus proches et nous associons le pixel à la classe majoritaire.




FIGURE 1.2 – Exemple d’application de l’algorithme K-plus proches voisins

**Support Vecteur Machine (SVM)** La Méthode de machine à support vectoriel (SVM) est une méthode qui résulte d’avancées théoriques en statistiques et en apprentissage [10][13]. La construction d’un modèle de classification est réalisée en deux étapes.

La première consiste à transformer l’espace d’entrée qui représente l’image en un espace de représentation intermédiaire de grande dimension dans lequel il est généralement possible de séparer linéairement les données.

La deuxième étape consiste à produire pour chaque paire de classe une frontière de décision linéaire. Cette frontière est un hyperplan qui classe les données d’apprentissage, c’est-à-dire qui sépare chaque paire de classe dans ce nouvel espace. L’hyperplan optimal est défini comme celui dont la distance entre les points les plus proches et lui-même, appelé marge, est maximisée. Il est construit de manière à se trouver le plus loin possible des objets d’apprentissage des deux classes. Cette action est intuitivement plus sûre.

La figure 1.3 illustre l’hyperplan qui sépare les deux classes.

Une légère variation des données ne modifie pas leur classification si la distance à l’hyperplan est grande. Les objets les plus proches de cet hyperplan sont appelés les vecteurs de support. La recherche de l’hyperplan dans l’espace intermédiaire de grande dimension est rendu faisable par le fait que la solution peut s’exprimer uniquement en fonction du produit scalaire dans cet espace [45].

Ce classifieur est beaucoup plus utilisé pour la classification binaire, c’est-à-dire entre deux classes, bien que des modèles multi-classes aient été proposés dans la littérature [12] [36].






FIGURE 1.3 – Représentation des SVM

### 1.3.5 Approche spectrale

En général, un pixel est représenté par un ensemble de données numériques, appelées "données caractéristiques".

Soient :

$v$  : l'espace des caractéristiques de l'image,

$v$  : le nombre de caractéristiques,

$x(i)$  : vecteur caractéristique associé à un pixel.

**Exemple :** Dans une image couleur, l'espace caractéristique de l'image est 3. Chaque pixel sera alors représenté par un point de coordonnées représentant les trois variables Rouge, Vert et Bleu.

Dans le cas de la classification d'une image satellitaire, les données caractéristiques sont les données spectrales obtenues par les différents capteurs, ils représentent le niveau de gris du pixel en question. D'autre part, en général, les classes recherchées sont connues à priori. La classification de l'image peut alors être considérée comme une classification supervisée dans l'espace des données spectrales. Les techniques de classification développées dans le domaine de la reconnaissance des formes sont généralement utilisées [62].

### 1.3.6 Approche texturale

Il n'existe pas une définition standard et précise de la texture, la notion de texture est l'une des moins bien définies ou tout au moins l'une de celles dont les

définitions font le moins l'unanimité des groupes de recherche. En effet, Les définitions académiques de la texture se restreignent souvent à des cas particuliers, l'une se réfère au tissage, une autre à la géologie. Cependant, un point commun unit toujours toutes ces définitions c'est la notion d'arrangement spatial. Nous pouvons dénombrer plusieurs définitions de la texture, pour Haralick et Gagallowicz la texture est un phénomène à deux niveaux, le premier concerne la description des primitives dont est composée l'image et qui sont ses propriétés caractéristiques, le deuxième implique la dépendance spatiale entre ces primitives [39].

Pour Serra, la texture est l'ensemble des propriétés spatiales, périodiques ou non, d'un phénomène se déployant dans le plan de l'image. L'étendue de ce phénomène et la géométrie de ses limites ne participent pas à la texture : seul importe le contenu spatial, exprimé en termes statistiques ou morphologiques, et non pas son contenu [56].

Quant à Gross et Wu, ils décrivent la texture comme étant un ensemble de primitives arrangées selon des règles particulières de placement.

Il existe deux types de textures, la texture aléatoire présentée dans la figure 1.4 qui est totalement désordonnée d'où l'impossibilité d'isoler des motifs de base et la texture périodique présentée dans la figure 1.5 qui est formée de primitives arrangées d'une façon particulière. Le motif de base se répète alors de manière régulière. Nous parlons de texture ordonnée [40].



FIGURE 1.4 – Exemples de texture aléatoire

L'analyse de texture regroupe un ensemble de techniques mathématiques permet-



FIGURE 1.5 – Exemples de texture périodique

tant de quantifier les différents niveaux de gris présents dans une image en termes d'intensité et de distribution.

Deux méthodes se distinguent, les méthodes statistiques et les méthodes structurales.

### ***Les méthodes statistiques***

Nous distinguons plusieurs variantes de méthodes statistiques, l'analyse des méthodes de premier ordre se fait au niveau des pixels individuels d'une région de l'image (région d'intérêt). Les paramètres sont calculés à partir de l'histogramme des intensités (ou histogramme du premier ordre). Celui-ci décrit au niveau de la région d'intérêt, choisit la fréquence d'apparition de chaque niveau sur l'échelle des gris. La moyenne, la variance et l'obliquité sont les paramètres les plus souvent utilisés pour caractériser une texture.

Pour palier aux lacunes des méthodes qui utilisent les paramètres du premier ordre qui ne donnent pas d'informations concernant la localisation du pixel, l'utilisation de méthodes d'ordre supérieur s'impose. L'ordre est donné par le nombre de pixels mis en jeu dans le calcul des paramètres.

La méthode de matrice de cooccurrence, qui permet de déterminer la fréquence d'apparition d'un motif formé de deux pixels séparés par une certaine distance dans une direction, est une méthode d'ordre deux [39].

La méthode des longueurs de plages de niveaux de gris est la méthode la plus connue des méthodes d'ordre supérieur, elle consiste à compter le nombre de plages d'une certaine longueur, de niveau de gris dans une direction donnée [40].

### *Les méthodes structurelles*

Les méthodes structurelles permettent de synthétiser des textures en modifiant ces règles d'arrangement. De telles méthodes semblent plus adaptées à l'étude de textures périodiques ou régulières.

Les méthodes structurelles se présentent toujours en deux phases. La première consiste en une définition des primitives. Une primitive est un ensemble connexe plus ou moins important de pixels de niveaux de gris à peu près semblables : il s'agit en fait d'un motif de base [40]. La deuxième phase quant à elle est une caractérisation des relations spatiales entre ces primitives [52].

#### 1.3.7 Approche floue

L'utilisation d'une partition nette impose une contrainte très gênante. En effet, toutes les méthodes de classification "dure" contraignent les pixels à être membre exclusif d'une et une seule classe, donc l'association d'un pixel à une seule classe est obligatoire alors que dans beaucoup de cas le pixel se trouve dans une zone commune à deux classes, d'où l'utilisation de la classification floue pour y remédier [62].

Dans la figure 1.6, Les individus 10 et 11 sont appelés sujets frontières, ils peuvent appartenir aux deux classes B et C.




FIGURE 1.6 – Processus de classification : sujets frontières

La classification floue remplace donc le degré d'appartenance dans une partition nette qui égale à 0 ou à 1 par un réel dans l'intervalle  $[0, 1]$ .

Parmi les algorithmes de classification floue les plus connues, nous distinguons l'algorithme des C-moyennes floues caractérisé par son autonomie due au fait qu'il

utilise un classificateur non-supervisé [6].

Il existe beaucoup d'autres méthodes de classification floue : généralisation du classifieur par les k-plus proches voisins [2][14], les classifieurs basés sur la notion d'intégrale floue [35], les classifieurs qui s'appuient sur l'utilisation de règles floues ou de réseaux neuronaux [70], les variétés de C-moyennes floues (FCM) proposées par Gustafson et Lessel [38] et Gath et Geva [30], etc.

Pour passer d'une partition floue à une partition Crisp, nous pouvons utiliser le processus de déffuzification, sachant qu'un vecteur de label associé à un pixel est un vecteur qui représente l'appartenance de ce dernier à l'ensemble des classes du système, le processus de déffuzification illustré dans la figure 1.7, consiste à mettre à 1 l'élément maximal de chaque vecteur label à 1 et à 0 le reste.




FIGURE 1.7 – Processus de déffuzification

### 1.3.8 Approche contextuelle

En ne prenant en compte que le pixel à classer lors de la phase de classification, nous nous privons d'une information très importante qui est le voisinage du pixel. En effet, en se penchant sur le voisinage du pixel et en le traitant comme étant membre d'un groupe de pixels, et non une entité indépendante, nous gagnons en consistance de la classification.

La classification contextuelle traite chaque pixel en se souciant de ces voisins immédiats et donc des relations spatiales qu'il entretient avec ces derniers.

Dans leur article, Gurney et Townsend [37] présentent les méthodes de classification intégrant l'information contextuelle proposée dans les années soixante-dix

et quatre-vingt. Pour Solaiman et *al.* [60], nous pouvons diviser les méthodes de classification contextuelle en deux types génériques qui sont la fusion contextuelle de données de sortie et la fusion contextuelle de données d'entrée.

Pour la fusion contextuelle de données de sortie, les relations entre pixels adjacents ne sont intégrées qu'en fin de classification. En effet, la classe attribuée à chaque pixel est modifiée en considérant les classes de ces voisins directs.

Pour la fusion contextuelle d'entrée, les relations entre pixels adjacents sont intégrées en début et au milieu de la classification.

### 1.3.9 Approche multi-sources

Une classification "multi-sources" est une classification qui combine des informations provenant de sources diverses [17][18][19] comme l'illustre la figure 1.8 : données multi-capteurs acquises par différents capteurs (image satellitaire et photo aérienne par exemple) ; données multi-temporelles acquises par un même capteur mais à des temps différents ; données exogènes telles que le modèle numérique de terrain ou la carte géologique ; données symboliques comme des connaissances représentées par des règles de production[62], etc.

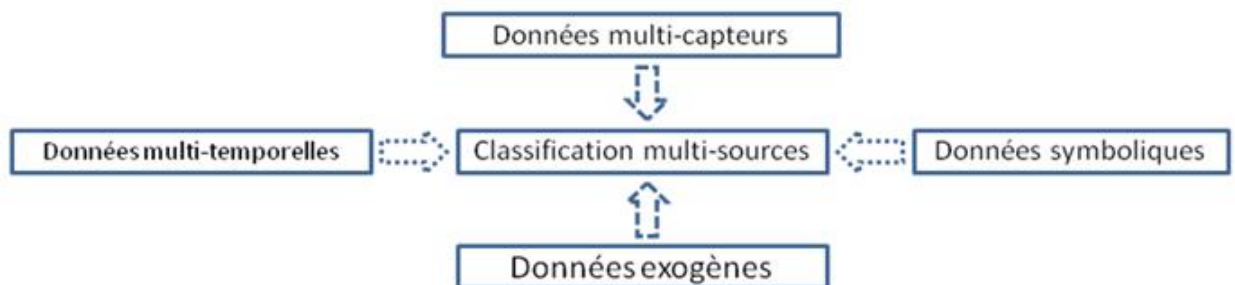


FIGURE 1.8 – Classification multi sources

Pour la caractérisation et le suivi de l'extension du tissu urbain de la région d'Alger, Smara et *al.* [59] présentent des techniques de fusion et de classification floue d'images multi-sources optiques et radar. La méthodologie développée se base sur un processus comprenant différentes phases dont la première concerne les prétraitements de toutes les données mises en jeu (superposition géométrique, réduction du speckle dans les images radar SAR, etc.).

La deuxième étape consiste à effectuer une classification floue non supervisée.

Des données exogènes, comme un modèle numérique de terrain, des cartes géologiques et topographiques, peuvent aussi être utilisées en plus des données spectrales [68] [58].

Pour palier à l'hétérogénéité des données satellitaires de résolution métrique (surfaces hétérogènes, ombres portées, etc) qui perturbe les méthodes de classification classique (spectrale) adaptées à l'analyse d'image de résolution décamétrique, et pour améliorer la classification des zones urbaines et périurbaines, Puissant et *al.* [54] proposent de développer des méthodes orientées 'objets' où chaque 'objet' représente un ensemble de pixels homogènes et est construit sur les caractéristiques élémentaires (spectrale, géométrique) et les relations spatiales entre les objets (texture et relations contextuelles).

### 1.3.10 Approche structurelle

L'approche structurelle permet d'ajouter de nouvelles informations et connaissances dans le processus de classification tels que les indices de formes et les mesures, les connaissances expertes et les relations spatiales entre les différentes régions qui constituent l'image.

Plusieurs approches ont été utilisées pour intégrer la notion de structure dans le processus de classification, parmi elles, nous citons l'approche par région qui est composée de trois étapes qui sont l'étape de prétraitement qui nous permet d'avoir les régions que nous décorons par les attributs structurels en deuxième étape pour finalement procéder à la phase de classification de ces régions.

Nous citons aussi l'approche par mise en correspondance de graphe ou l'approche par modification de région (AMR) [62] qui innove par rapport aux autres approches en intégrant l'information structurelles pixel par pixel et non plus par région. C'est cette information structurelle que nous modélisons et utilisons dans notre recherche afin d'améliorer le processus de classification des images satellitaires haute résolution et spécialement les images de la forêt.

### 1.3.11 Classification hybride

La classification permet d'extraire des connaissances à partir d'un ensemble de données. Pour cela, de nombreuses méthodes ont été développées et ont montré leur pertinence dans de nombreux domaines. Cependant chacune de ces méthodes présente des limites ou des inconvénients. De plus, pour un même jeu de données, ces méthodes donnent des résultats sensiblement différents et surtout de types différents. En effet, aucune approche de classification n'est générique. Par exemple, pour certaines images, l'utilisation de l'approche spectrale peut donner de très bon résultats vu que pour ces images la radiométrie est discriminante et elle permet une excellente séparation entre les classes. De même pour la texture ou pour l'approche multi-source ou structurelle. Or ce n'est pas toujours le cas et pour avoir une bonne classification il faut essayer de mixer entre les approches de classification ce qui permet d'avoir une approche hybrides capables de donner une bonne classification.

Wemmert [67] propose dans sa thèse une nouvelle approche qui consiste à intégrer différents types de méthodes de classification non supervisée et à les faire collaborer par un processus de raffinement automatique et mutuel de leurs résultats. Ceci permet d'utiliser des mécanismes d'unification (méthode de vote, reclassification, etc.) et d'en augmenter leur efficacité.

## 1.4 Conclusion

Dans ce chapitre, nous avons présenté différentes méthodes de classification citées dans la littérature.

Le but principal des tentatives d'amélioration de la classification est d'essayer de s'approcher au maximum du photo interprète humain. Plusieurs approches ont été introduites afin d'optimiser la classification. L'introduction de l'information texturale ou contextuelle permet de traiter le point en se penchant sur son voisinage. L'approche multi-sources quant à elle permet l'intégration de plusieurs données tels que les données exogènes, ponctuelles, multi-capteurs ou multi-temporelles pour améliorer le processus de classification de l'image.

La plupart de ces méthodes traitent le pixel individuellement. Or si nous regar-



dans l'image d'un point de vue global et que nous nous préoccupons des objets qui la compose, une nouvelle information est alors utilisée pour encore améliorer la classification : C'est l'information structurelle. Dans le chapitre suivant, nous présentons les informations et connaissances structurelles ainsi que les différentes approches de classifications structurelles présentes dans la littérature.



# Chapitre 2

## Classification structurelle

Haralick et *al.* (1973) ont dit : "À la recherche des caractéristiques significatives pour décrire les images, il est naturel de regarder les types de caractéristiques utilisées par l'homme dans l'interprétation de l'information issue des images".

## 2.1 Introduction

Au cours du processus de classification, le photo-interprète humain n'utilise pas uniquement des informations ponctuelles et contextuelles. En effet, l'un des facteurs essentiels dans l'analyse du photo-interprète est l'utilisation de paramètres de formes et des relations spatiales entre les objets de la scène à classer. Ce qui nous permet de dire que malgré l'apport des informations multi-sources et contextuelles dans le processus de classification, le regard porté sur l'image reste trop local et les résultats obtenus sont encore loin de pouvoir rivaliser avec ceux obtenus par le photo-interprète humain.

Notre objectif est de pouvoir intégrer les informations et les connaissances structurelles dans le processus de classification des images satellitaires haute résolution. Dans ce cadre, nous nous intéressons essentiellement aux images de la forêt. Dans ce chapitre, nous exposons les différents aspects de la classification structurelle en définissant ces différentes composantes et en essayant de faire le tour de ces différentes approches. Nous commençons par définir les informations et les connaissances structurelles. Nous passons ensuite aux mesures et indices de formes en passant par les relations spatiales. Finalement, nous présentons quelques approches structurelles proposées dans la littérature.

## 2.2 Informations et connaissances structurelles

### 2.2.1 Informations structurelles

Une information structurelle est tout ensemble de données extrait à partir d'une région et qui concerne sa forme, son aspect géométrique ainsi que les relations spatiales qui la relie avec les autres régions[62]. Nous citons parmi les informations structurelles les mesures tels que l'aire et le périmètre, les indices de formes tels que la circularité ou encore les relations spatiales tels que la relation d'adjacence.

### 2.2.2 Connaissances structurelles

Une connaissance est une maîtrise intellectuelle acquise par l'apprentissage, la recherche ou l'expérience. Les connaissances structurelles sont des connaissances

expertes qui décrivent les classes en utilisant des informations concernant la forme des régions sous l'apparence desquelles les classes se manifestent et les relations spatiales entre ces régions. Les connaissances de ce type sont rarement intégrées pixel par pixel dans le processus de classification.

Ce sont donc des connaissances qui se basent sur l'information structurelle. Voici quelques exemples de connaissances expertes structurelles effectivement acquises dans le cadre d'un problème de classification géomorphologique d'image d'atoll

"La classe (rempart) se présente souvent sous la forme de petits arcs de cercle"

"La classe (grand motu) se présente souvent sous la forme de régions rectangulaires"

"La classe (mare) peut parfois exister entre la classe (motu) et la classe (rempart)"  
[62]

## 2.3 Mesures et indices de formes

### 2.3.1 Mesures

La "mesure" d'une forme est toute valeur ou ensemble de valeurs numériques mesurées sur la forme.

Les mesures possèdent ou non des dimensions : trois dimensions (le volume), deux dimensions (la surface), une dimension (le périmètre, le diamètre euclidien, la longueur de l'axe principal, etc.) et aucune dimension (le nombre de composantes connexes, le nombre de trous, etc.) [63].

### 2.3.2 Les indices de formes

#### *Définition*

Un indice de forme est tout paramètre, coefficient ou combinaison de coefficients permettant de donner des renseignements chiffrés sur la forme de l'objet.

La majorité des indices sont créés à partir d'une égalité ou d'une inégalité inhérente à la forme que nous souhaitons caractériser. La possibilité de construire un indice à partir d'une égalité (ou inégalité) propre à la forme que nous souhaitons caractériser, est l'avantage majeur des indices de formes. Cela permet d'utiliser les indices pour tout type de forme. De plus, la complexité de calcul d'un indice

réside dans la complexité d'extraction des mesures qui le compose. Ces avantages rendent cette technique particulièrement bien adaptée en classification.

### ***Propriétés***

Les indices de formes doivent avoir les propriétés suivantes :

#### **Propriété 2.1**

Les indices de formes doivent être :

- Sans dimension,
- Invariants par homothétie,
- Invariants par rotation et translation
- S'appliquer à des formes connexes simples.

Le calcul d'un indice de forme est équivalent au calcul de la valeur d'une fonction à plusieurs variables. Nous aimerions alors que cette fonction soit bijective. Cependant, deux contre exemples sont donnés par les indices de concavité qui valent 1 pour toutes les formes convexes et l'indice d'allongement par le diamètre pour le disque et le carré :

$$\text{Allongement}(\text{Disque}) = \text{Allongement}(\text{Carre}) = 1/2$$

#### **Propriété 2.2**

Soient  $F1$  une forme et  $I$  un indice de forme tel que  $I(F1) = \alpha$ , avec  $\alpha$  constante réelle. Alors pour toute forme  $F2$ , si on a  $I(F2) \neq \alpha$  alors  $F1 \neq F2$ . Ce qui peut s'écrire :

$$\forall F1, \forall F2, \forall I / I(F1) \neq I(F2) \Rightarrow F1 \neq F2$$

Cette dernière propriété implique qu'un indice seul ne peut pas identifier une forme, mais qu'il "renseigne" sur la forme étudiée et sur les caractéristiques qu'elle ne possède pas [63].

### ***Différents indices de formes***

#### **– Coefficient de Gravelius**

Dans leur article [1], Bendjoudi et *al.* introduisent quelques indices de forme utilisés dans la reconnaissance des bassins versants et en particulier le coefficient

de Gravelius. En effet, les classiques de l'hydrologie proposent pour caractériser la géométrie d'un bassin versant différents indices de forme destinés à comparer les bassins, voire à estimer certaines de leurs caractéristiques hydrologiques.

La première idée est d'essayer de comparer le bassin versant à un bassin standard en utilisant les indices de formes. L'indice le plus pertinent dans ce cas de figure est l'indice de Gravelius  $K$  (2.1) Cet indice a été proposé en 1914 par Gravelius (1861-1938), professeur à l'Université de Dresde (Allemagne). Cet indice est défini comme le rapport du périmètre du bassin à celui d'un cercle de même surface. Si le périmètre du bassin est noté  $P$  et sa surface  $A$ , le coefficient de compacité s'exprime par l'équation (2.1) :

$$k = \frac{P}{2\sqrt{\pi A}} = 0.28 \frac{P}{\sqrt{A}} \quad (2.1)$$

Sachant que le cercle est la figure dont la surface est maximale pour un périmètre donné ou, de façon duale, la figure dont le périmètre est minimal pour une surface donnée, nous devons donc nous attendre à ce que le périmètre de tout bassin soit supérieur à celui du cercle de même surface. Le coefficient de Gravelius est donc nécessairement supérieur à l'unité. Il vaut par exemple environ 1.12 pour un bassin carré, et est d'autant plus grand que le bassin est allongé.

#### – Indice de Gibson et Indice d'excentricité

Dans l'article de David et *al.* [15], les auteurs étudient plusieurs formes de maladies myocardiques et valvulaires en se basant sur les formes géométriques des ventricules.

Pour cela, une étude sur les formes géométriques des ventricules et leurs caractéristiques a été réalisée pour essayer de suivre leurs états en se basant sur les changements de leurs formes en fonction du temps.

Pour caractériser les changements et les variations de forme du ventricule en fonction du temps et voir leurs effets sur la forme pour pouvoir identifier les problèmes et les anomalies, une étape d'apprentissage a été réalisée sur différents individus regroupés en trois catégories. La première catégorie est celle de personnes normales et saines, la deuxième est la catégorie des personnes atteintes d'une régurgitation aortique, la dernière catégorie est celle des

personnes souffrant d'une régurgitation mitrale.

Pour caractériser la forme, les auteurs ont utilisé deux indices de formes, l'indice de circularité de Gibson CSI (2.2) et l'indice d'excentricité E (2.3). L'indice de circularité de Gibson est le ratio entre l'aire de la forme et l'aire du cercle ayant la même circonférence. Cet indice informe sur la circularité. En effet, plus l'indice s'approche de 1, plus la forme est circulaire et plus il s'approche de 0 elle est linéaire. Cet indice est aussi répandu dans la littérature sous le nom de déficit isométrique.

$$CSI = \frac{4\pi A}{C^2} \quad (2.2)$$

Pour l'indice d'excentricité, il a été défini en utilisant un modèle elliptique, en effet les mesures utilisées pour cet indice sont la longueur de l'axe majeur L et celle de l'axe mineur D.

Cet indice s'approche de 0 pour un cercle, dans ce cas  $L = D$ , et s'approche de 1 pour une ligne, dans ce cas  $D = 0$ .

$$E = (L^2 - D^2)^{1/2} / L \quad (2.3)$$

#### – Indice Wellipse de Thibault

Thibault *et al.* [63] quant à eux, ont utilisé les indices de forme dans le but de reconnaître les cellules relatives à la maladie de progéria. Cette maladie est une maladie orpheline et on en compte une centaine de cas dans le monde, elle provoque un vieillissement accéléré du patient.

Les auteurs disposent d'un ensemble de noyaux de cellules prélevés chez les patients et d'une expertise de ces noyaux qui affirme que la forme des noyaux normaux joue un rôle important dans le diagnostique.

En effet, les noyaux pathologiques diffèrent des noyaux sains par leurs convexités et leur forme elliptique mais déformées. Les auteurs ont donc réalisé une classification en deux classes, des noyaux sains et des noyaux pathologiques et ils ont créé un modèle contenant des indices de forme et des caractéristiques texturales. Une phase d'apprentissage et une phase de validation ont été réalisées à partir de ce modèle. Parmi les indices de forme introduits par Thibault *et al.*,



nous avons l'indice Wellipse (2.4) qui caractérise la forme elliptique.

$$\text{Wellipse} = \pi \text{ Rmin Rmax} / A \quad (2.4)$$

Avec  $A = \pi ab$  représente l'aire d'une ellipse, et  $R_{\max}$  le demi grand axe et  $R_{\min}$  le demi petit axe.

– **Indice de Morton**

Pour Forestier [27], et dans le cadre de ces travaux pour la classification de la végétation urbaine, l'utilisation des indices de forme est nécessaire pour la caractérisation géométrique des segments obtenus après une première étape de segmentation.

En effet, après avoir obtenu un ensemble de segments, Forestier va associer à chaque segment un ensemble de caractéristiques en fonction de leur réponse spectrale mais également de leur forme.

L'ensemble des caractéristiques est divisé en trois catégories : les caractéristiques spectrales, les caractéristiques de dimension et enfin les caractéristiques de forme dérivés des caractéristiques de dimension. Le choix de ces caractéristiques a été effectué en accord avec des experts géographes.

Pour les caractéristiques de forme, plusieurs indices de forme ont été utilisés pour caractériser les régions. Parmi les indices de forme utilisés par Forestier, il y a l'indice de Morton (2.5) qui permet par exemple d'apprécier l'étalement de la forme par rapport à la surface. Cependant, l'interprétation de cet indice ne permet pas de savoir si la valeur d'allongement obtenue est réellement due à l'allongement de l'objet ou si elle relate un fort taux de concavité. Soit  $L$  l'élongation,  $S$  la surface et  $P$  le périmètre.

$$morton = \frac{S}{\pi(0.5 \times L)^2} \quad (2.5)$$

Forestier a aussi utilisé l'indice de Miller (2.6) qui permet d'appréhender la circularité de la forme.

$$simple = \sqrt{S} / L^2 \quad (2.6)$$

## 2.4 Les relations spatiales

Les relations spatiales entre les régions sont des informations très intéressantes vues qu'elles sont plus stables que les propriétés des objets elles-mêmes. Elles fournissent une information structurelle et peuvent constituer un outil de description des objets et un outil qui permettra d'aider à la décision en cas d'ambiguïté. Elles sont un moyen efficace de décrire des scènes structurées et sont potentiellement utiles dans de nombreux domaines d'application tels que l'imagerie aérienne, la reconnaissance de visages, l'imagerie médicale, la classification, etc.

Nous pouvons distinguer différentes relations spatiales telles que l'adjacence, l'inclusion, distance entre les régions, la direction, etc.

Bloch et *al.* [5] traitent l'information spatiale ternaire "entre" qui, à cause de son caractère vague et contextuel, a poussé les auteurs à utiliser des modèles flous et à envisager plusieurs définitions selon l'extension spatiale des objets. En effet, nous ne pouvons pas traiter les relations spatiales suivantes " l'arbre est entre la maison et la route ", " la route est entre les deux immeubles ", " la route est entre la maison et la plage ", " le magasin est entre la maison et le boucher ", ou encore " la route est entre la voie ferrée et la plage " de la même façon. En effet, l'extension des objets est la cause de cette différenciation, ainsi, la représentation de " - est entre \* et \*\* " prendra des formes différentes selon que \* ou \*\* est étendu, que - est étendu, ou que plusieurs objets sont étendus.

Colliot et *al.* [9] utilisent les relations spatiales dans une procédure de segmentation. En effet, les auteurs ont élaboré une description des structures cérébrales à partir des relations spatiales les liant. Cette description présente les structures de façon hiérarchique, les structures d'un même niveau étant liées par des relations. Les relations spatiales utilisées sont de quatre types : adjacence, direction, distance et symétrie, voici quelques exemples de règles utilisées "le thalamus est en dehors du troisième ventricule et en dessous du ventricule latéral " pour la direction, " le noyau caudé est proche du ventricule latéral " pour la distance, " le thalamus est adjacent au troisième ventricule " pour l'adjacence et enfin " les structures homologues des deux hémisphères (par exemple " pour la symétrie"). Afin d'introduire les relations spatiales dans un système de classification ou de segmentation, deux types d'approches ont été utilisés : les méthodes qualitatives

et les méthodes quantitatives. Les premières reposent souvent sur la logique formelle [55] [64] [66], ou sur des extensions du calcul des intervalles et ne peuvent pas être intégrées dans un cadre numérique comme celui des modèles déformables. [9].

À l'inverse, les méthodes quantitatives fournissent une évaluation numérique des relations. Celles reposant sur les ensembles flous sont particulièrement intéressantes car elles permettent de modéliser l'imprécision qui peut être issue des traitements effectués sur l'image mais aussi être intrinsèque aux relations. Plutôt que de définir une relation en "tout-ou-rien", nous en définissons un degré de satisfaction.

Nous distinguons deux types d'approches floues pour la représentation de relations spatiales : soit en définissant une valeur représentant le degré de satisfaction entre deux objets donnés, soit en définissant un ensemble flou représentant, en tout point de l'espace, le degré de satisfaction de la relation par rapport à un objet de référence. La première approche a été appliquée à de nombreuses relations : adjacences floues [4], distances [3], symétries entre objets flous [9].

## 2.5 Approches de classification structurelle

L'utilisation de l'information structurelle dans le processus de classification des images de télédétection est limitée. Nous présentons l'ensemble des approches proposées dans la littérature. Cette présentation ne pourrait être des plus exhaustives, cependant nous présentons le maximum de travaux existants.

### 2.5.1 Classification structurelle basée sur une approche par régions

Dans leur majorité, les systèmes basés sur une approche par région se présentent en trois étapes : une première étape que nous appelons *étape de prétraitement* qui consiste en une étape de segmentation ou de classification en régions élémentaires. Le but de cette première étape est de déterminer les régions à traiter vu que l'intégration de l'information structurelle ne peut généralement se faire que sur des régions et non sur des pixels. Au cours de cette étape, seules des données spectrales et autres données ponctuelles sont utilisées.

La deuxième étape est une étape intermédiaire au cours de laquelle l'ensemble des caractéristiques structurelles qui sont utilisées au cours de la troisième et dernière étape sont calculées pour chaque région.

La dernière étape est une étape de reclassification dans le cas où le prétraitement est une classification ou une étape de classification sinon. Chaque région est classée en se basant sur le modèle de classification contenant les caractéristiques structurelles.

Dans l'article de Carleer et Wolf [8], les auteurs ont proposé une approche permettant l'identification des classes de carte d'occupation des sols en Belgique, et en particulier les zones urbaines, rurales et agricoles et surtout les types de récolte. Les auteurs ont utilisé une classification basée sur les connaissances structurelles pour essayer d'arriver à une bonne classification.

Dans le cas d'images caractérisées par des distances intra-classes élevées et des distances interclasses faibles, la classification utilisant uniquement l'information spectrale ne donne pas de résultats satisfaisants. Pour remédier à ce problème, les auteurs proposent l'utilisation de l'information structurelle afin d'améliorer la classification automatique. Ainsi, les auteurs proposent une approche en trois étapes.

La première étape consiste en une segmentation qui permet l'obtention de régions homogènes, la technique de segmentation utilisée est la croissance de région.

Dans la deuxième étape, chaque région se transforme en une unité d'analyse et des mesures structurelles, spectrales et texturales seront alors calculées. Les caractéristiques structurelles utilisées dans ce système sont la surface, le périmètre, la compacité ( $\text{région}/\text{périmètre}^2$ ) et ainsi de suite.

La dernière étape est la classification des régions en utilisant la distance de Bhattacharyya en se basant sur les caractéristiques extraites à partir de chaque région. Giraudon et *al.* [31] ont développé le système MESSIE, ce système est une architecture multi spécialistes, bâtie autour d'une architecture de type tableau noir, dont l'objectif est de réaliser une interprétation basée uniquement sur une connaissance générique des objets sans utiliser de connaissances exogènes à la donnée image.

Les auteurs montrent comment une modélisation des objets physiques de la scène exprimée sous quatre points de vue peut améliorer la classification. Les quatre

points de vue du système sont la forme, le contexte, l'aspect et la fonction.

La forme caractérise la forme géométrique de l'objet. Quand les auteurs parlent de forme, ils parlent de façon générique. En effet, cette vue modélise des objets qui peuvent sembler différents dans la réalité, ceci est causé par la variation de forme, la dimension ou bien encore l'orientation des objets.

Le contexte est relatif à la connaissance que le système a priori des relations spatiales qu'un objet peut avoir avec d'autres objets par exemple une ombre est à côté d'un bâtiment, une voiture est sur une route, un pont est sur une rivière. Il se traduit par une liste " d'heuristiques de localisation " définies par deux objets et une relation spatiale. Cette connaissance, utilisée pour guider l'analyse de la scène, n'est pas liée au point de vue géométrie ou radiométrie. Elle reste vraie, quelle que soit la modélisation de la route ou de la voiture, et quel que soit le capteur utilisé.

L'aspect est la caractérisation de la connaissance sur l'apparence visuelle des objets, liée à l'aspect radiométrique dans l'image. La fonction correspond à la fonctionnalité de l'objet, par exemple, une route est une "voie d'accès".

Ce système est capable de manipuler des connaissances ponctuelles (informations radiométriques) et structurelles (propriétés géométriques, relations spatiales). Chaque spécialiste a une tâche spécifique et indépendante des autres spécialistes. Pour communiquer entre eux, les spécialistes utilisent une zone mémoire commune qui est le tableau noir. Plusieurs rôles sont assignés aux spécialistes tels que l'extraction des objets, Le calcul des caractéristiques structurelles, l'évaluation des hypothèses, l'étiquetage des objets, la détection des conflits, etc. Le système peut facilement accepter de nouvelles connaissances expertes et de nouveaux spécialistes.

### **2.5.2 Approche par mise en correspondance des graphes**

L'utilisation des graphes dans la classification des images est très répandue dans la littérature, cela est dû au fait que cette représentation soit compacte, structurée, complète, et assez facile à manipuler. Beaucoup de domaines ont utilisé les graphes tels que la segmentation, la détection de contours, la reconnaissance des formes : caractères, objets (bâtiments 2D ou 3D, structures cérébrales, etc.),

reconnaissance de visages (avec ou sans modèle).

Les graphes sont utilisés pour modéliser les informations structurelles sur les objets à reconnaître, et dans la plupart des cas nous utilisons les graphes d'adjacences pour modéliser les scènes à analyser. Dans ce type de graphes, les nœuds représentent les régions de l'image et les arcs sont les relations spatiales entre ces régions. En ce qui concerne les informations structurelles, elles sont représentées par des attributs qui décorent les nœuds pour les caractéristiques géométriques et les arcs pour les relations spatiales. Ces caractéristiques sont représentées par des couples attribut/valeur. La classification est alors effectuée en mettant en correspondance deux graphes : le graphe de référence, qui représente une référence à laquelle nous comparons le graphe de donnée qui lui représente la scène à analyser.

Nous distinguons deux types de graphe de référence qui sont le graphe modèle et le graphe aléatoire.

- **Le graphe de référence modèle** Le graphe de référence peut être le résultat de connaissances expertes, ce graphe est alors appelé *graphe de référence modèle*. Dans l'étude de Deruyver et Hodé [16] qui traite un problème de reconnaissance de parties anatomiques du cerveau humain, le graphe de référence de la figure 2.1 [16] est réalisé à partir de livres et de revus scientifiques. Pour chaque région, des caractéristiques structurelles comme la forme, la taille, l'orientation de chaque région et les relations spatiales entre deux régions sont calculées. L'image de la scène à analyser est ensuite segmentée, les caractéristiques structurelles calculées, un graphe spécifique à cette segmentation appelé *graphe de données* est ensuite réalisé et enfin une mise en correspondance entre ces deux graphes est enfin effectuée pour étiqueter le graphe de données.
- **Le graphe de référence aléatoire** Un deuxième type de graphe de référence est le graphe aléatoire présenté dans la figure 2.2 [44]. Dans cette figure, les  $\alpha_i$  représentent les sommets du graphe alors que les  $\beta_{ij}$  représentent les arcs de ce graphe. Ce graphe est utilisé dans le cas où la référence n'a pas une structure fixe. Les figures 2.2 (a) et 2.2 (b) [44] montrent un appariement entre deux graphes différents et le graphe de la figure 2.2 (a). Le graphe utilisé comme modèle est un graphe aléatoire (GA), constitué de variables aléatoires corres-

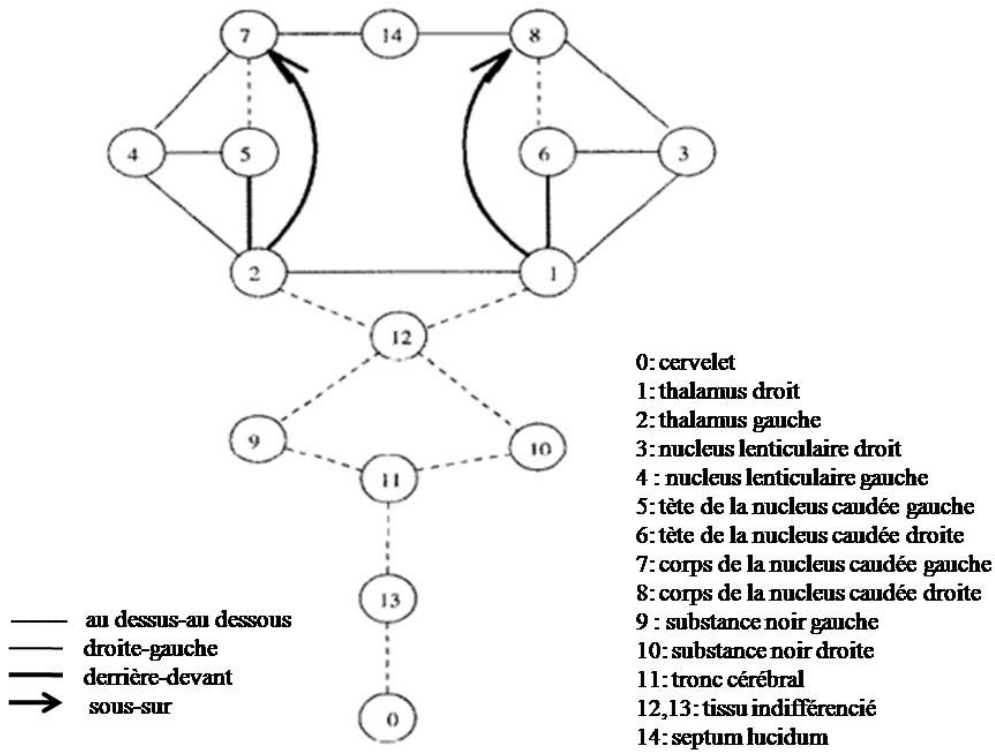


FIGURE 2.1 – Exemple de graphe de référence modèle : Représentation parties anatomiques du cerveau humain

pendant aux sommets ( $\alpha_i$ ) et aux arcs ( $\beta_{ij}$ ).

Dans ces travaux [44], Mangin essaie d'identifier les sillons du cerveau. La reconnaissance des sillons revient à étiqueter les nœuds du graphe extrait de l'image IRM, les sillons corticaux changent de représentation structurale d'un cerveau à l'autre, donc l'utilisation d'un graphe de référence modèle est impossible. Le choix a été donc fait et une approche qui s'inspire des modèles de la reconnaissance des objets supportés par des résultats récents en neurosciences, à savoir une méthode fondée sur l'apprentissage de la forme de plusieurs exemples de chacun des sillons a été adoptée.

La base de l'apprentissage est un ensemble d'images étiquetées par un neuroanatomiste. Un autre anatomiste doté d'une vision différente des plissements corticaux peut être à l'origine d'une seconde base d'apprentissage, éventuellement fondée sur les mêmes cerveaux, qui conduirait à entraîner un système concu-




FIGURE 2.2 – Mise en correspondance entre un graphe aléatoire et un graphe de référence

rent. La reconnaissance des sillons est donc considérée comme un problème de mise en correspondance de graphes, qui remplace le problème de recalage iconique usuel.

Pour définir la mise en correspondance idéale, Mangin utilise une méthode d'optimisation qui ressemble à la maximisation d'une mesure de similarité dans les méthodes de recalage. La mesure structurale utilisée découle d'une vision probabiliste du problème. Le graphe modèle est doté d'une structure de graphe aléatoire, et la probabilité à posteriori d'un étiquetage est modélisée à partir d'une distribution de Gibbs.

La scène traitée est d'abord segmentée puis représentée par un graphe où les attributs de chaque nœud sont les étiquettes (classes) possibles et la valeur attachée à chaque étiquette est la probabilité que le nœud prenne cette étiquette, de même pour les arcs.

L'étiquetage optimal correspond au minimum global de l'énergie associée à cette distribution.

### 2.5.3 Approche par Modification de Régions (AMR)

Cette approche a été élaborée par Suzuki [62]. Elle consiste à améliorer une première classification en intégrant les informations structurales dans un processus de reclassification.

Le système élaboré par Suzuki commence par une classification floue, le classi-



fiEUR utilisé est un classifieur flou quelconque. Des connaissances ponctuelles et contextuelles peuvent être intégrées pixel par pixel dans la classification à l'aide de données exogènes. Le résultat de cette pré-classification est une partition floue. Pour pouvoir rendre cette partition Crisp, l'auteur passe par une défuzzification qui donnera la partition Crisp initiale. C'est cette partition qui sera améliorée par l'intégration de connaissances structurales.

Outre la partition crisp initiale, la partition floue obtenue par la première classification est elle aussi utilisée comme entrée pour L'AMR.

Cette approche ne modifie que la partition nette pour essayer de l'améliorer et de l'adapter aux connaissances structurales disponibles. La partition floue n'est pas modifiée par l'AMR. La figure 2.3 [62] montre les différentes étapes de ce système de classification.

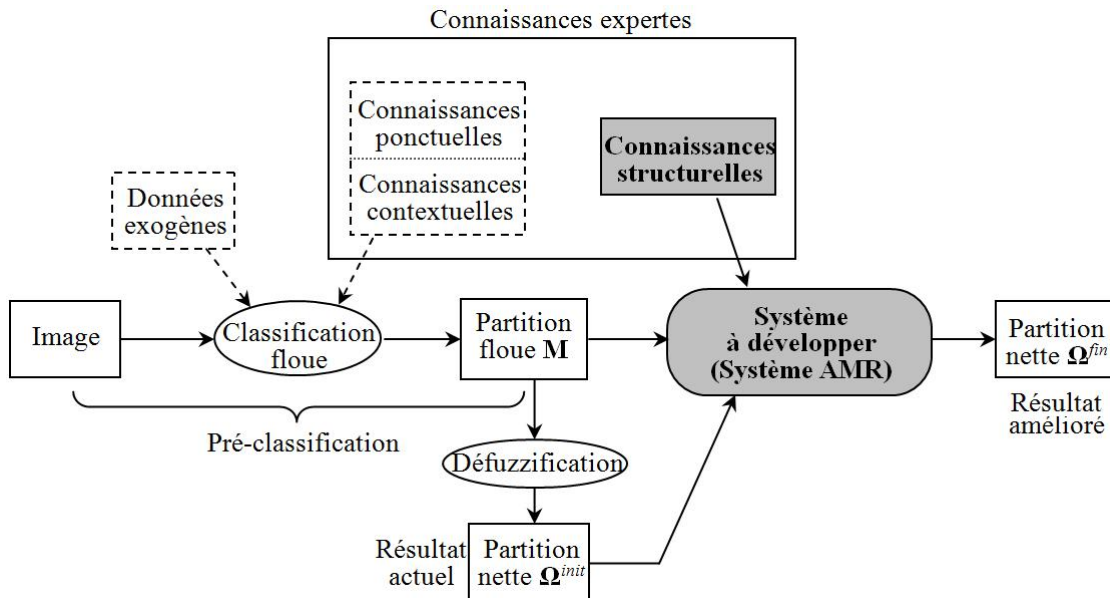


FIGURE 2.3 – Vue d'ensemble du système de classification utilisant des connaissances expertes

Le système AMR est itératif. À chaque itération, la partition nette courante qui est au départ égale à la partition initiale est modifiée de manière à ce qu'elle se conforme de mieux en mieux aux connaissances structurales. Le résultat final est la partition nette modifiée et se conformant le mieux aux connaissances structurales du système.

AMR innove en intégrant les informations structurales pixel par pixel. En effet,

AMR améliore la partition nette courante en utilisant une stratégie d'optimisation combinatoire. À chaque itération, la partition courante rivalise avec une partition candidate obtenue en réassignant un pixel  $p$  sélectionné par un choix aléatoire pondéré à une classe différente de la classe à laquelle il appartient. La probabilité qu'un pixel donné soit choisi est déterminée par les degrés d'appartenance dans la partition floue.

Dans la partition nette candidate, pour chaque région nette assignée à une classe pour laquelle on dispose de connaissances structurales, un degré d'adéquation entre la région et les connaissances est calculé. En combinant les degrés d'adéquation de toutes les régions impliquées, une évaluation globale de la partition nette peut être réalisée. C'est le calcul d'un degré d'adéquation globale  $Q$ .

Enfin, le système décide si oui ou non la partition candidate doit être acceptée en tant que partition nette courante de l'itération suivante. La décision est prise en comparant le degré d'adéquation globale  $Q_{\text{cond}}(\text{partition candidate})$  avec celui  $Q_{\text{cour}}(\text{partition courante})$ . Le processus vise à maximiser le degré d'adéquation globale par une méthode heuristique d'optimisation combinatoire. Cette stratégie est illustrée dans la figure 2.4 [62].

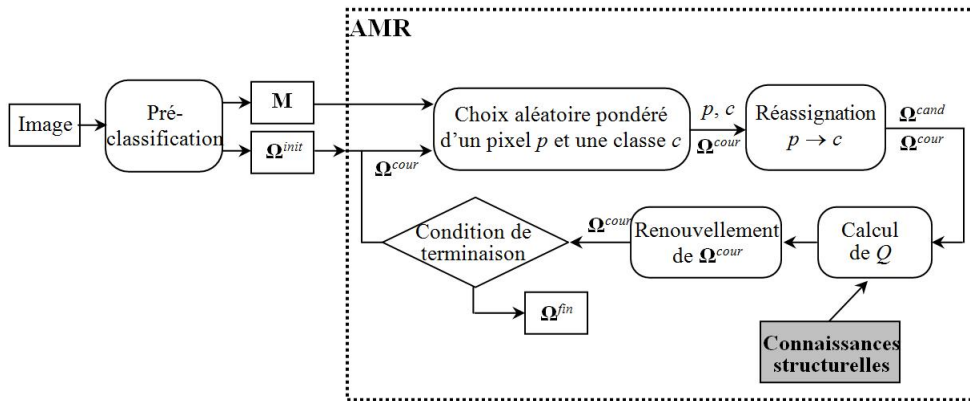


FIGURE 2.4 – Vue d'ensemble du système AMR

#### 2.5.4 Approche par sur-segmentation

L'approche par sur-segmentation a été élaborée pour remédier à un problème qui peut apparaître dans les approches précédentes. En effet, la plupart de ces ap-

proches reposent sur l'hypothèse que les différentes régions dans l'image peuvent être mises en évidence de manière précise par l'étape préliminaire. Or cette hypothèse n'est pas toujours vraie, c'est ce que nous pouvons constater dans la figure 2.5 [62] qui montre deux segmentations différentes, la première est de bonne qualité (figure 2.5 (a)) alors que la deuxième l'est beaucoup moins.

Plusieurs paramètres peuvent causer une mauvaise segmentation. En effet, et dans le cas de l'utilisation uniquement des informations ponctuelles dans la phase de prétraitement, il y a nécessairement des lacunes dans l'identification des régions et donc il peut y avoir perte de certaines régions ou bien un surnombre de régions. Il peut aussi y avoir une déformation des régions par rapport au résultat attendu. Le problème est que la plupart du temps ces erreurs là ne peuvent pas être modifiée ou réparée dans les étapes suivantes du processus de classification et donc l'erreur survenue dans l'étape de prétraitement va persister tous au long de la classification.




FIGURE 2.5 – Exemples conceptuels de qualité de segmentations préliminaires : (a) classification attendue ; (b) bonne segmentation préliminaire qui conduirait à obtenir une classification de bonne qualité ; (c) mauvaise segmentation préliminaire

Pour remédier à ce problème, l'utilisation d'une sur-segmentation est une solution efficace. Une sur-segmentation en fragments suffisamment petits peut permettre d'éviter le cas des objets absorbés dans les régions adjacentes, et pour obtenir les classes voulues, une fusion des régions, en prenant en compte les caractéristiques structurelles, donne de bons résultats.

Le résultat obtenu dans la figure 2.6 [62] montre l'efficacité de cette méthode. La sur-segmentation (figure 2.6 (b)) de l'image initiale a permis de corriger les lacunes de la segmentation perçue dans la figure 2.5 d'où une bonne classification

(figure 2.6 (c)).




FIGURE 2.6 – Exemples conceptuels de l’approche par sur-segmentation :  
(a) classification attendue ; (b) résultat de sur-segmentation ; (c) résultat de  
classification

Dans leur article, Sonka *et al.* [61] traitent un problème de reconnaissance d’IRM du cerveau humain, la première étape du système est une sur-segmentation de l’image en petites régions. La deuxième étape est une recherche de la meilleure combinaison de classification des régions. Cette étape est réalisée à l’aide d’un algorithme génétique. Ainsi, chaque ensemble de régions adjacentes affectée à la même classe est considéré comme une seule région. Pour chaque région, un ensemble de caractéristiques géométriques est calculé et un degré d’adéquation à la connaissance structurale concernant la forme de la région est obtenu.

Pour les relations spatiales, un graphe est construit où chaque nœud représente une région et chaque arc signifie la relation entre les deux régions où des caractéristiques spatiales entre régions sont calculées et où un degré d’adéquation à la connaissance structurale concernant les relations spatiales entre les régions est attaché.

Finalement, une fonction de fitness est définie de sorte que plus les degrés d’adéquation des régions sont élevés, plus le degré de fitness est élevé.

### 2.5.5 Approche par modification des degrés d’appartenance dans une partition floue

Zehana *et al.* [69] ont proposé une approche par modification des degrés d’appartenance dans une partition floue. Le système commence par une classification

floue, des degrés d'appartenance pour chaque pixel et pour chacune des classes cherchées sont produits. Donc il existe une image de chaque fonction  $\{k(x)\}$  du degré d'appartenance à la classe  $k$ .

Un passage de régions floues vers des régions Crisp est nécessaire pour calculer les caractéristiques structurales de ces régions. Chaque région floue est caractérisée par un ensemble de régions Crisps, et pour chacune de ces régions Crisps, les caractéristiques géométriques (surface, périmètre, compacité, forme, etc.) et les relations avec les autres régions (distance, inclusion, etc.) sont calculées selon l'exigence des connaissances structurales considérées.

Un degré d'adéquation est aussi calculé pour chaque région. Ce degré d'adéquation est fusionné avec le niveau de la coupe de la région considérée par la fonction de combinaison basé sur le système Mycin [7][57] de manière à augmenter le niveau de la coupe si le degré d'adéquation est fort et à le diminuer si le degré est faible. Enfin, l'ensemble de régions nettes obtenu (ensemble des  $\alpha$ -coupes avec leurs niveaux modifiés) constitue la région floue modifiée. La figure 2.7 illustre l'approche de Zehana *et al.* La figure 2.7(a) représente l'image du degré d'appartenance à une classe  $k$ . Le profil de cette image est représenté dans la figure 2.7(b) sachant que l'auteur a comme connaissance " la classe  $k$  est de forme ronde ". Dans la figure 2.7(c), nous observons l'image de degrés d'appartenance modifiée. Les niveaux des  $\alpha$ -coupes qui se conforment bien à la connaissance augmentent (la région floue gauche) et ceux qui ne se conforment pas à la connaissance diminuent (la région floue droite) [62].




FIGURE 2.7 – Schéma conceptuel de l'approche par modification des degrés d'appartenance dans une partition floue

## 2.6 Conclusion

Dans ce chapitre, nous avons fait le point sur la classification structurale. En effet, nous avons défini l'information structurale qui représente toute information concernant la forme des régions et leurs aspects géométriques ou les relations spatiales qui les relient et les connaissances structurales qui représentent les connaissances expertes basées sur les informations structurales.

Nous avons aussi présenté différentes approches de classifications structurales. Chacune de ces approches a des avantages et des inconvénients et chacune d'entre elles présente de meilleurs résultats pour un certain type d'images et dans des contextes différents.

La plupart de ces approches commence par une étape de prétraitement qui est la plupart du temps une étape de segmentation qui permet d'extraire les régions de l'image. Dans notre recherche, nous traitons les images de la forêt et plus particulièrement la classification des images forestière à l'arbre prêt d'où la nécessité d'extraire les couronnes d'arbres de l'image. Dans le chapitre suivant, nous présentons la segmentation en région et plus particulièrement les approches d'extractions de couronnes d'arbres.

## Chapitre 3

# Identification des formations forestières à partir des images haute résolution

## 3.1 Introduction

Dans ce chapitre, nous allons définir la segmentation en régions et en présenter les principaux algorithmes. Dans ce cadre, nous présentons une revue des principales méthodes d'extraction de couronnes d'arbres existantes. Ces méthodes permettent l'obtention d'inventaire forestier à " l'arbre près " et d'autres informations extrêmement importantes concernant le patrimoine forestier tel que le volume des arbres. Un bilan des différentes approches de segmentation sera présenté en fin de ce chapitre.

## 3.2 Segmentation par région

### 3.2.1 Définition

La segmentation est une étape importante pour l'extraction des informations quantitatives de l'image. Elle fournit une description de haut niveau.

La segmentation consiste à créer des partitions dans l'image en identifiant des pixels similaires. Le critère de similarité permet de contrôler l'aspect final de la segmentation. La mesure de la similarité de deux pixels est donc le point clé des techniques de segmentation. Il convient alors de choisir avec soin la méthode de calcul de la similarité.

Nous énumérons plusieurs méthodes de regroupement des pixels tels que le regroupement par couleur, le regroupement par homogénéité, ou encore le regroupement par taille.

La segmentation a pour objectif de différencier des zones d'intérêt dans l'image. C'est généralement une première étape d'un traitement plus complexe comme le filtrage adaptatif ou la reconnaissance de formes.

Les méthodes de segmentation étant sensibles au bruit, il est important d'appliquer des prétraitements pour atténuer ce bruit et améliorer la qualité de l'image. La segmentation par région consiste à construire des surfaces en regroupant des pixels voisins suivant un critère d'homogénéité. Elle crée un ensemble de régions qui ont les propriétés suivantes :

- la réunion de toutes les régions donne l'image entière.
- les régions sont connexes (c'est à dire que tous les pixels d'une même région



sont jointifs).

- tous les pixels d’une même région sont homogènes entre eux.
- les pixels de deux régions adjacentes ne sont pas homogènes entre eux.

### 3.2.2 Algorithmes de segmentation par région

#### *Décomposition/Fusion*

Cette technique enchaîne deux phases :

\*La première phase consiste à découper itérativement l’image jusqu’à avoir des blocs contenant exclusivement des pixels similaires.

\*La deuxième consiste à regrouper les blocs voisins s’ils sont similaires.

Les deux phases sont nécessaires afin de garantir que les régions obtenues sont à la fois homogènes et également les plus ”grandes” possibles. Chaque phase étant indépendante, nous les étudions séparément.

#### – **La décomposition :**

La méthode de découpage de l’image utilisée dans cet algorithme est basée sur la notion de ” quadtree ”. Cette structure de données est un arbre quaternaire qui permet de stocker l’image à plusieurs niveaux de résolution. Le départ de la décomposition est fait à partir d’une région initiale qui est l’image toute entière. Si cette image vérifie un critère d’homogénéité, l’algorithme s’arrête. Sinon, la région est découpée en quatre parties de même taille dans lesquelles la procédure est lancée récursivement. La région initiale est stockée comme un nœud dans un graphe et les sous parties comme des fils de ce nœud.

#### – **La Fusion :**

La procédure de découpage décrite précédemment aboutit à un nombre de régions trop élevé. La cause fondamentale de cette sur-segmentation est que l’algorithme découpe les régions de manière arbitraire. Il se peut qu’il coupe de cette façon une zone homogène en deux ou quatre parties.

La solution, qui correspond à la phase de fusion de l’algorithme, est de procéder à une fusion de régions après le découpage. Il faut tout d’abord définir le critère de similarité entre blocs. Le plus simple est d’étendre la définition de similarité entre les pixels définie lors de l’étape de décomposition. Ainsi, le bloc est

assimilé à un " gros " pixel.

### ***Croissance de régions***

Cette approche consiste en un processus d'agrandissement de régions autour d'un point de départ considéré comme le centre de la région. Cette approche est composée de deux parties :

\*La première partie est la recherche des points de départ des régions.

\*La deuxième est l'extension des régions à partir des points de départ.

#### **– Extraction des points de départ :**

Le choix des points de départ est la partie critique de l'algorithme. En effet, l'étape de croissance utilise une mesure de similarité pour choisir les pixels à agglomérer. Si le point de départ est situé dans une zone non homogène, la mesure de similarité va produire de fortes variations et la croissance va s'arrêter très tôt. Par conséquent, il convient de choisir les points de départ dans les zones les plus homogènes possibles.

Pour trouver ces zones, le principe de décomposition utilisé dans l'algorithme décomposition/fusion être utilisé. Comme la décomposition finale donne une liste de blocs homogènes, il suffit de choisir le centre des plus gros blocs pour avoir des points de départ satisfaisant.

#### **– Croissance :**

Cette étape a pour objectif de faire grossir une région en agglomérant des pixels voisins. Les pixels sont choisis afin de maintenir l'homogénéité de la région. Pour cela, un indicateur d'homogénéité est défini. Les pixels voisins sont ajoutés à la région si l'indicateur d'homogénéité reste vrai. La croissance s'arrête lorsque l'ajout de pixels brise l'homogénéité.

### ***Ligne de partage des eaux***

Cette technique consiste à faire grossir simultanément toutes les régions jusqu'à ce que l'image soit entièrement segmentée. Elle tire son nom d'une analogie avec la géophysique. En effet, les valeurs d'intensité des pixels d'une image sont considérées comme une information d'altitude. Dans ce cas, l'image est représentée comme un terrain en trois dimensions comme illustré dans la figure

3.1. Le principe est alors de remplir progressivement d'eau chaque bassin du terrain. Chaque bassin représente une région.




FIGURE 3.1 – Représentation d'une image sous forme de terrain 3D et remplissage des bassins avec de l'eau

Comme le montre la figure 3.2, lorsque l'eau monte et que deux bassins se rejoignent, la ligne de rencontre (la ligne de partage des eaux) est marquée comme une ligne de frontière entre les deux régions.




FIGURE 3.2 – Ligne de partage des eaux entre 2 bassins

– **Carte d'élévation :**

La carte d'élévation est une image dont les valeurs représentent une altitude. Pour construire cette image nous partons du gradient de l'image.

Dans la carte d'élévation, l'altitude la plus élevée est assignée aux pixels ayant un fort gradient ainsi qu'aux bords de l'image. Cela donne les lignes de crête. La valeur d'altitude des autres pixels est calculée en fonction de l'éloignement de la ligne de crête : plus nous nous éloignons de la ligne de crête, plus l'altitude doit décroître.

– **Remplissage des bassins par infiltration :**

Il existe de nombreux algorithmes permettant de réaliser le remplissage des bassins.

Nous détaillons ici un algorithme utilisant la technique de croissance de régions.

Dans cet algorithme, le remplissage des bassins est un procédé itératif qui consiste à élever progressivement le niveau de l'eau de zéro à une valeur maximale. À chaque itération, les bassins existants sont remplis (extension des régions) et de nouveaux bassins sont éventuellement créés (nouvelles régions).

### 3.3 Extraction des couronnes d'arbres

Les méthodes d'extraction de couronnes d'arbres sont généralement regroupées en quatre grandes familles qui sont : les détections de maximums locaux, les approches contour, les approches régions et les approches objets.

#### 3.3.1 Approche par maximums locaux

Il s'agit d'algorithmes simples qui donnent en sortie la localisation de chaque couronne. Cette approche se base sur l'hypothèse suivante : La réflectance d'une couronne est maximale dans le sommet. Elle identifie les pixels clairs entourés de pixels de plus faible intensité à l'intérieur de fenêtres de taille fixe ou variable. Cette hypothèse n'est pas toujours vraie mais elle est maximale lorsque les paramètres de dimensions du filtre utilisés pour la détection de ces derniers et de lissage sont adaptés aux dimensions des arbres.

Beaucoup de tentatives ont été faites pour améliorer la position des sommets en essayant d'intégrer quelques corrections sur les maximums locaux. Par exemple, Pouliot *et al.* [53], et en partant des maximums locaux, essaient d'extraire la différence absolue entre la bande NIR et la bande rouge. À partir de cette différence, ils réajustent les positions des sommets des arbres après observation des niveaux de gris dans les disques englobant ces maximums.

Le résultat obtenu par ce type d'algorithmes est généralement restreint à la détection des couronnes d'arbres et donc l'estimation de leurs nombre en calculant le nombre des maximums locaux dont le niveau de gris est supérieur à un certain seuil.

Verbeke et al [65] quant à eux, extraient le nombre de couronnes d'arbres et calculent la densité d'arbres dans la parcelle à partir des statistiques qui dérivent

les distances entre les maxima locaux.

Cette approche peut aussi être une étape initiale pour les approches régions, les algorithmes de cette approche utilisent les maximums locaux déjà localisés comme point de départ pour établir un processus de délinéation des couronnes d'arbres.

### 3.3.2 Approche contour

Dans la perspective de mesurer la taille des arbres, l'un des paramètres les plus importants à extraire est le contour de ces derniers [34]. Des algorithmes fondés sur une délinéation des couronnes d'arbre et qui préservent la forme de la couronne ont été développés. L'un des algorithmes les plus connus est l'algorithme du suivi des vallées ("valley-following") [32]. Cet algorithme utilise les bandes d'ombre autour des arbres qui sont révélatrices de leur présence comme illustré dans la figure 3.3 [34].




FIGURE 3.3 – Vue tridimensionnelle d'une petite partie (16\*20 pixels) représentant les cimes plus brillantes comme des montagnes souvent séparées par des vallées d'ombre

L'hypothèse de départ de cet algorithme est que les couronnes des arbres sont perçues distinctement sur les images à haute résolution parce qu'elles constituent des entités brillantes séparées par des zones d'ombre.

Cet algorithme s'étale sur trois étapes :

- **Suivi des zones d'ombres** : un procédé de "suivi des vallées" parcourt de multiples chemins entre les arbres pour essayer de suivre les zones d'ombre qui se profilent généralement entre les houppiers des peuplements forestiers denses, de la même manière que le suivi des vallées entre des montagnes. Cela donne une assez bonne séparation des cimes des arbres, bien que souvent incomplète.

Comme nous le voyons dans la figure 3.4, les chemins entre les arbres sont présentés par les zones d'ombres.




FIGURE 3.4 – Extrait d'une carte topographique 3D d'une portion de forêt

- **Délinéation des couronnes :** Cette étape consiste en un procédé à base de règles qui examine individuellement les arbres potentiels et suit la limite de la couronne dans le sens des aiguilles d'une montre en cherchant à délinéer des zones fermées.
- **Séparation ou regroupement des zones fermées :** Cette étape est une intégration de règles d'ordre supérieur permettant de prendre des décisions concernant l'utilisation d'outils additionnels pour séparer ou regrouper davantage ces zones fermées.

À partir de ce stade, les couronnes individuelles sont considérées et traitées comme des objets distincts dans toutes les analyses ultérieures. Le résultat de l'exécution de cet algorithme présenté par Gougeon and Leckie est présenté dans la figure 3.5 [33].

Le bon déroulement de cet algorithme repose sur trois seuils qui varient en fonction de la qualité des images et des couronnes des arbres elles mêmes. Ces trois seuils interviennent dans les différentes étapes de prétraitements et de traitements de l'image le long du processus d'extraction des couronnes.

- **Le seuil inférieur :** Il permet d'éliminer du traitement les étendues dépourvues d'arbres importants et celles qui se trouvent essentiellement à l'ombre. Il est utilisé comme simple seuil sur toute l'image et permet de masquer tout pixel présentant un niveau de gris inférieur à sa valeur. Ceci accélère le traitement et empêche l'algorithme de créer des vallées inutiles et vides de sens à l'intérieur de ces étendues.




FIGURE 3.5 – Résultat de l'exécution de l'algorithme de "suivi des vallées"  
 (a) section de taille  $100 \times 100$ ; (b) Résultat après l'exécution de l'algorithme de  
 "suivi des vallées"; (c) Résultat final après l'intégration des règles expertes

Une valeur trop élevée peut entraîner une mauvaise délimitation des couronnes ainsi que des mesures inappropriées de leur surface. Une valeur trop faible entraînera quant à elle une mauvaise séparation des couronnes à l'intérieur des groupes d'arbres.

- **Le seuil supérieur** : Il a comme fonction d'aider à distinguer les vallées utiles à la séparation des cimes d'arbres de celles trouvées généralement à de plus grandes résolutions spatiales (10-40 cm/pixel). Ces derniers ont tendance à séparer les couronnes en plusieurs parties, particulièrement dans le cas d'espèces présentant des couronnes en forme d'étoile.
- **Le seuil de rugosité des vallées** : Il représente une mesure de la quantité d'instabilité radiométrique à laquelle nous devons nous attendre et que nous pouvons tolérer dans les vallées [33].

### 3.3.3 Approche Région

Une autre approche proposée dans la littérature est l'approche région, Ericksson[22] propose une approche qui se base sur l'algorithme de croissance de régions par mouvement brownien "region growing by brownion motion". L'algorithme présenté dans cette approche est divisé en quatre étapes :

- **Prétraitement** : Le prétraitement commence par un seuillage permettant

de se débarrasser de tout ce qui diffèrent des arbres tels que le sol nu et les roches ainsi de suite. À partir de l'image seuillée, la matrice de distance  $D$  qui représente la distance de chaque point de l'image par rapport à l'arrière plan est créée.

L'étape de prétraitement est terminée par le lissage de la matrice  $D$  par un filtre gaussien.

- **L'extraction des maximums locaux :** Par hypothèse, les maximums locaux représentent les sommets des couronnes d'arbres. L'extraction des maxima locaux se fait en appliquant un masque  $3 \times 3$  sur l'image lissée.
  
- **L'extraction des couronnes d'arbres :** Cette troisième étape est entamée par la création de l'image Numpass avec la taille de l'image initiale. Cette image est créée en partant de tous les maximums locaux extraits dans la première partie de l'algorithme. Pour chacun d'entre eux, le phénomène de mouvement brownien qui représente le mouvement aléatoire d'une particule en suspension dans un fluide [22][23] est simulé. En effet, il s'agit de sommer des 2D vecteurs aléatoires, la somme des  $n$  vecteurs aléatoires est la position de la particule après  $n$  étapes.  
Pour s'assurer que la particule ne dépasse pas les limites des régions et atterrit dans le background et avant d'ajouter le vecteur à la somme nous vérifions si le fait de l'ajouter ne propulse pas la particule vers un pixel noir donc de niveau de gris égal à 0. L'image Numpass présente alors le nombre de passages de la particule pour chaque pixel.
  
- **La limitation des frontières :** La création de régions et l'obtention de l'image segmentée est le résultat de l'extraction des frontières entre les couronnes qui chevauchent. Ceci permet d'affecter chaque pixel à la région à laquelle il appartient tout en extrayant les frontières entre ces dernières.

Le schéma dans la figure 3.6 illustre le fonctionnement de l'algorithme.

Le bon fonctionnement de cette approche dépend beaucoup de trois paramètres essentiels :

- **Le seuil inférieur :** Il a le même rôle que celui présenté dans l'algorithme du



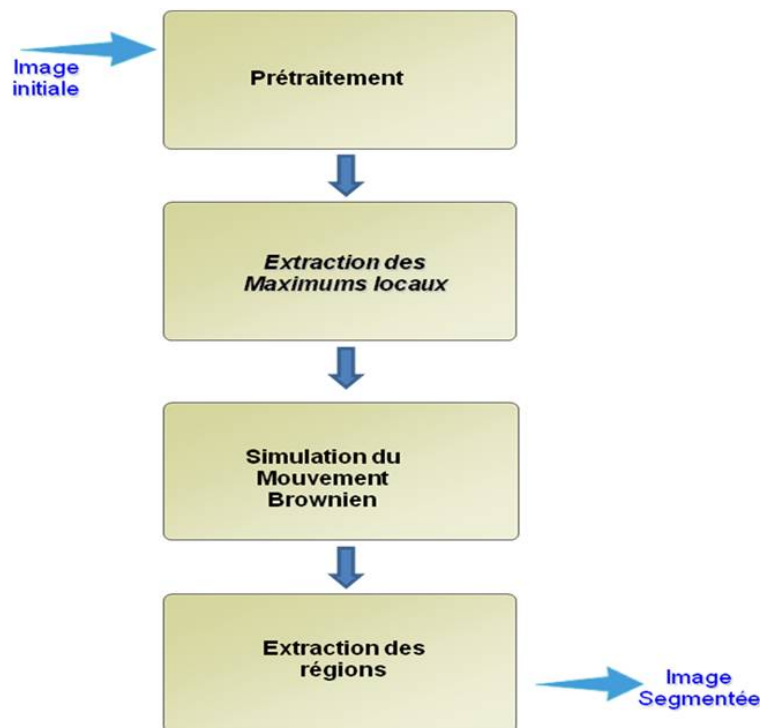


FIGURE 3.6 – Croissance de région par mouvement Brownien

suivi des vallées.

- **La taille de la fenêtre :** C'est la taille de la fenêtre qui permet l'extraction des maximums locaux. Cette fenêtre dépend de la taille des arbres. Une mauvaise estimation de la fenêtre peut générer un excès ou une sous estimation des maximums locaux.
- **Le nombre de pas :** Le troisième paramètre est le nombre de pas utilisé dans le mouvement brownien, une sous-estimation ou une surestimation de ce dernier peut engendrer une anomalie au niveau de la taille de la couronne ou de sa forme.

### 3.3.4 Approche Objet

L'approche objet est une approche qui se base sur le calcul de patrons. Les patrons sont des rendus mathématiques de l'apparence des arbres de différents formats, géométries et points de vue. L'extraction des couronnes d'arbres se fait en essayant de chercher l'occurrence des patrons dans l'image.

Larsen et Rudemer [43] utilisent des patrons elliptiques qui dérivent d'un modèle

optique de la couronne des arbres (figure 3.7). La forme des arbres est modélisée par un ellipsoïde généralisé illustré par l'équation 3.1 où  $z$  est l'axe vertical,  $a$  la demi hauteur de la couronne,  $b$  sa demi largeur et  $n \geq 1$  un paramètre de forme.

$$\left[ ((x^2 + y^2)^{n/2})/b^n + ((z^2)^{n/2})/a^n = 1 \quad (3.1) \right]$$




FIGURE 3.7 – Approche objets : différentes formes de patrons

(a) :  $n = 1$ , forme conique, (b) :  $n = 2$ , forme d'ellipsoïde

Un modèle de réflexion / absorption de la lumière par le feuillage de l'arbre et par le sol est constitué pour obtenir le patron. Ce modèle nécessite la donnée de la position du soleil et de la caméra, ainsi que la hauteur et la taille approximative des couronnes pour calculer le patron. La recherche des maximums locaux de la fonction de corrélation des transposées de ce patron dans l'image conduit à trouver un certain nombre de positions des arbres. Il est à noter que des méthodes de post-traitement, lorsque l'on connaît certains paramètres comme le nombre d'arbres a priori, permettent d'affiner le résultat. Par exemple, cette valeur peut être estimée à l'aide d'une recherche de maxima locaux sur l'image lissée par convolution avec une gaussienne pour les arbres situés près du point Nadir (figure 3.8) [49].

Perrin *et al.* [50] quant à eux modélisent les peuplements forestiers par un processus ponctuel marqué.

Dans cette approche, les auteurs essayent de modéliser tout d'abord l'arbre en se posant la question suivante : comment peut-on distinguer les arbres de l'image et de les séparer ? La réponse est la même que celle trouvée la plupart du temps, il s'agit des ombres des arbres elles mêmes (figure 3.9), orientées dans une direction privilégiée ou des ombres de leurs voisins, ce qui crée une zone sombre.




FIGURE 3.8 – Prise de vue des photographies aériennes et point Nadir : projeté orthogonal sur le sol de la caméra




FIGURE 3.9 – Ellipse et sa frontière

L'auteur cherche donc à extraire des images des objets  $x$  dont la distribution interne des niveaux de gris diffère de celle de leur environnement proche  $F(x)$  qui est la fonction représentative de la frontière.

Pour quantifier cette différence, il utilise la distance de Bhattacharya. Cette distance représente la différence entre les distributions de niveaux de gris des pixels de deux ensembles. Pour cela, l'auteur suppose que ces distributions sont des gaussiennes, dont les paramètres sont calculés à l'aide d'estimateurs classiques.

Une fonction de qualité  $Q_a(d)$  est alors calculée pour une distance donnée  $d \in \mathbb{R}^+$ . L'énergie d'attache aux données  $U_d$  d'un objet  $x$  est égale à la fonction de qualité définie au niveau de l'équation (3.2) :

$$Q_a(d) = \begin{cases} V_M \left[ 1 - \frac{d}{d_0} \right] & \text{si } d < d_0 \\ V_m \left[ 1 - \exp \left( \frac{-(d-d_0)V_M}{d_0|V_m|} \right) \right] & \text{sinon} \end{cases}$$

$$U_d(x) = Q_a(d_B(x, F(x))) \quad (3.2)$$

Ainsi, il est essentiel de faire en sorte que les objets qui répondent bien aux données, avec une forte valeur de  $d_B(x, F(x))$ , aient un potentiel négatif pour être attractifs.

Le principal paramètre à fixer est donc la distance  $d_0$  au delà de laquelle un objet aura une énergie d'attache négative. Seuls des objets avec une distance de Bhattacharya au dessus de ce seuil seront acceptés à très basse température. Les autres paramètres de la fonction de qualité  $Q_a(d)$  sont des paramètres de seuil, afin que  $Q_a(d) \in [V_m; V_M]$  :

Les résultats de l'extraction de couronnes d'arbres obtenues par Perrin sont représentées dans la figure 3.10 [49].




FIGURE 3.10 – Extrait d'une plantation de peupliers

Gauche : extrait d'une plantation de peupliers, Saône et Loire. Droite : résultat de l'extraction

### 3.4 Bilan et comparaison

Nous avons présenté quatre approches différentes pour l'extraction des couronnes d'arbres, la première remarque que nous pouvons faire est qu'aucune approche n'est parfaite et qu'aucune d'entre elles ne peut s'adapter à toutes les images et à tous les types de forêts.

- **L'approche par maximums locaux** : Cette approche est généralement restreinte à la détection des couronnes d'arbres et donc l'estimation de leurs nombres. L'un de ces problèmes majeurs est sa faible robustesse par rapport à la taille de la fenêtre qui influe sur la taille des arbres et sur leurs formes, mais aussi par rapport à la qualité des images et à leur contenu souvent très complexe. Ces problèmes provoquent beaucoup d'anomalies telles que les fausses alarmes sur les forêts des images non denses et la mauvaise estimation du nombre de couronnes.
- **L'approche contour** : Pour l'approche contour, nous avons évoqué l'algorithme de suivi des vallées qui est optimal pour les formes coniques d'arbres, vu qu'elles créent naturellement des zones d'ombre entre les tiges. Par contre, un problème surgit pour les gros arbres vu que l'algorithme a tendance à les casser. Un autre inconvénient rencontré consiste dans la provocation de fausses alarmes dans les zones ouvertes et donc une détection excessive et exagérée de couronnes peut avoir lieu. Finalement le choix du seuil est primordial pour le bon fonctionnement de la méthode, un mauvais seuil peut entraîner une détérioration de la forme des arbres en cas de seuil élevé ou un seuil faible qui ne permet pas de se débarrasser du bruit.
- **L'approche région** : Pour l'approche région, nous avons évoqué l'algorithme de croissance de régions par mouvement brownien. Le premier inconvénient de ce dernier est sa dépendance de différents paramètres tels que le seuil, la taille de la fenêtre pour l'extraction des maximums locaux et enfin le nombre de pas pour la simulation du mouvement Brownien.  
L'hypothèse de départ de cette algorithm qui stipule que les maximums locaux représentent les sommets des couronnes n'est pas toujours vrai, chose qui peut

détériorer les performances de l'algorithme.

- **L'approche Objet** : Le principal inconvénient l'approche objet est que le calcul des patrons nécessite plusieurs données qui ne sont pas toujours disponibles. L'indisponibilité d'une de ces données peut provoquer une perte des forme des patrons et donc une mauvaise reconnaissances des régions.

La comparaison des algorithmes d'extraction des couronnes d'arbres a été rarement traitée dans la littérature[24] [25] [50]. Erickson *et al.* proposent une comparaison entre trois algorithmes, le processus ponctuel marqué, noté PPM, la croissance de régions [22][23], noté RG et le troisième est une approche hybride par champs de Markov à trois états, décrite dans [25], noté MRF. Perrin[49] y ajoute un quatrième algorithme proposé par Larsen [42]. C'est l'algorithme d'appariement de patron("template matching") noté TM. Les résultats des tests obtenus sont représentés dans les figures 3.11 et 3.12.




FIGURE 3.11 – Extraction des arbres dans des zones denses

- (a) extraction avec l'algorithme PPM (491 objets) ; (b) extraction avec l'algorithme TM (411 objets) ; (c) extraction avec l'algorithme RG (800 objets) ; (d) extraction avec l'algorithme MRF (376 objets)






FIGURE 3.12 – Extraction des couronnes d’arbres dans des zones éparses  
(a) extraction avec l’algorithme PPM (866 objets) ; (b) extraction avec  
l’algorithme RG (1023 objets) ; (c) extraction avec l’algorithme MRF (934  
objets)

Pour l'image de futaie dense de la figure 3.11, l'algorithme RG présente le meilleur résultat, les autres algorithmes ont tendance à sous estimer le nombre d'arbres. Pour l'image de plantation de la figure 3.12, les différents algorithmes ne rencontrent pas de problème de détection à l'intérieur de la plantation et nous ne remarquons pas une différence entre les résultats obtenus. La différence majeure entre eux se focalise dans leurs façons d'appréhender les zones de non végétations. Pour cet aspect, c'est l'algorithme PPM qui donne les meilleurs résultats. Donc pour conclure cette comparaison, nous réaffirmons qu'aucun algorithme existant dans la littérature n'est adapté à tous les types de forêts et que chacun a des avantages et des inconvénients suivant l'image à traiter [49].

## 3.5 Conclusion

Nous avons présenté dans ce chapitre le processus de segmentation des images en régions et en particulier les différentes méthodes d'extraction de couronnes d'arbres existantes.

Nous avons présenté quatre approches d'extraction des couronnes présentes qui sont l'approche par maximums locaux, l'approche contour, l'approche région et l'approche objet. Nous avons alors constaté que l'efficacité de ces approches en matière d'extraction des couronnes dépend du type de l'image traité, de sa résolution et de la nature des formations forestières qu'elle contient .



## Chapitre 4

# Systeme de classification basé sur l'intégration des informations et des connaissances structurelles

## 4.1 Introduction

Dans ce chapitre, nous décrivons le système que nous avons élaboré et qui consiste à intégrer des informations et des connaissances structurelles dans le processus de classification des images forestières haute résolution.

Nous présentons son architecture basée sur une phase de segmentation, une phase de caractérisation des régions, une phase d'apprentissage et enfin une phase de classification impliquant les informations et les connaissances structurelles.

## 4.2 Architecture du système

Nous avons présenté dans le chapitre 2 plusieurs approches de classification structurelle. Notre choix c'est porté sur l'approche par régions. Cette approche s'avère la plus adaptée à notre domaine d'application. En effet, le premier facteur sur lequel nous nous sommes basés est l'absence de connaissances structurelles concernant la forme des arbres et qu'ils ne possèdent pas de forme géométrique exacte même si nous savons que les couronnes d'arbres ont la plupart du temps une forme proche de celle d'un cercle ou d'une ellipse.

L'approche par modification de régions n'est donc pas adéquate pour notre contexte vu qu'elle se base sur des connaissances expertes sur la forme des objets pour les classer et qu'elle opère au niveau pixel alors que nous classons des régions. Nous avons écarté aussi l'approche par modification des degrés d'appartenance dans une partition floue et l'approche par sur-segmentation sachant qu'elles se basent aussi sur des connaissances structurelles concernant la forme des régions. En effet, l'approche par sur-segmentation procède à la classification des régions par regroupement des segments en maximisant le degré d'adéquation aux connaissances structurelles concernant la forme de la région obtenue.

Il nous reste alors deux approches qui peuvent nous convenir et qui sont l'approche par régions et l'approche par mise en correspondance de graphes.

L'approche par mise en correspondance de graphes se base sur l'appariement entre deux graphes qui sont le graphe de donnée qui représente la scène à analyser et le graphe de référence.

Pour notre travail, c'est le graphe de référence qui fait défaut. En effet, la référence

que nous avons est l'inventaire forestier qui nous informe sur des groupements d'arbres et non sur des arbres individuels. D'où l'impossibilité de réaliser un graphe de référence.

Notre choix s'est donc porté sur l'approche par régions qui nous permet d'intégrer les informations et les connaissances structurelles dans le processus de classification.

Nous utilisons donc une approche par régions. Cette approche est composée de trois phases :

- **Phase de prétraitement :**

Cette phase est une segmentation qui va permettre d'extraire les couronnes d'arbres.

- **Caractérisation des régions :**

Cette phase est celle de l'extraction des caractéristiques. C'est lors de cette phase que les informations structurelles seront intégrées.

- **Classification des régions :**

C'est lors de cette phase que les régions seront classées en fonctions des caractéristiques extraites.

Pour permettre la classification des régions, nous procédons à une étape d'apprentissage. Un modèle de données est alors construit à partir d'un ensemble d'images étiquetées à partir de l'inventaire forestier. L'intégration des connaissances structurelles est réalisée après la phase de classification. La figure 4.1 représente l'architecture de notre système.

## 4.3 Extraction des couronnes d'arbres

L'étape de segmentation est très importante dans notre processus de classification. En effet, l'extraction des couronnes d'arbres et donc des régions sur lesquelles le reste du processus va s'appliquer, est une étape critique du processus. Une mauvaise segmentation implique donc des régions déformées et une explosion ou une sous-estimation du nombre des régions. Le choix de la méthode de segmentation adéquate doit donc prendre en compte ces considérations. Aucune

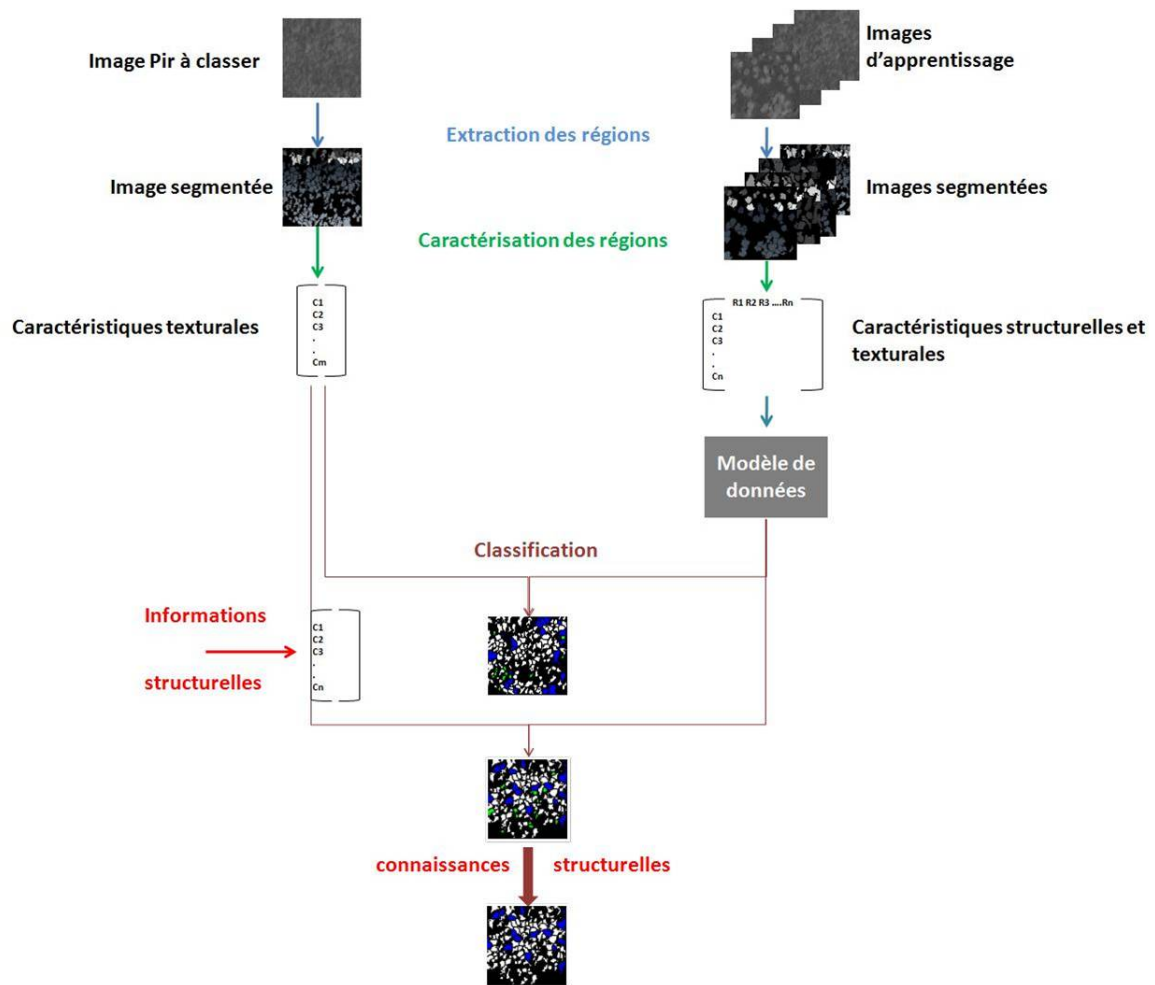


FIGURE 4.1 – Architecture du système

approche existante ne peut permettre une segmentation parfaite, mais le choix de la méthode utilisée doit minimiser les erreurs et permettre la meilleure extraction possible des couronnes.

#### 4.3.1 Choix de l'algorithme de segmentation

Notre choix s'est porté sur un algorithme de type croissance de région. Cet algorithme est l'algorithme de croissance de région par mouvement Brownien. Quatre approches d'extraction de couronnes d'arbres ont été présentées dans le chapitre 3.

– **L'approche par maximums locaux :**

Cette approche n'est pas la plus appropriée pour notre travail. En effet, cette approche est plus adaptée pour l'estimation du nombre d'arbres et leur localisation et les contours détectés par cette approche ne sont pas très précis.

– **L'approche Objet :**

Cette approche se base sur le calcul de patrons qui nécessite plusieurs données telles qu'une estimation du nombre d'arbres, la taille ou l'aire des couronnes sans lesquelles les formes géométriques des patrons ne peuvent pas être bien décrites et les couronnes vont être déformées.

L'application de cette approche se trouve donc contrainte par la non disponibilité des paramètres de calcul des patrons ce qui nous a empêché de la traiter.

Reste alors deux approches, l'approche contour et l'approche région.

– **L'approche contour :**

La plus part des algorithmes liés à l'approche contour sont optimaux pour les formes coniques d'arbres[34]. Pour les arbres ayant de larges couronnes, ces algorithmes ont tendance à provoquer des cassures dans les couronnes et à créer donc une sur-segmentation.

Le deuxième inconvénient de ces algorithmes est qu'ils provoquent de fausses alarmes dans les zones ouvertes et donc un nombre de régions supérieur au nombre réellement existant dans la scène à classer.

Finalement, un mauvais choix des seuils utilisés peut provoquer une détérioration de la forme des couronnes.

– **L'approche Région :**

Les algorithmes de l'approche région présentent le même inconvénient que ceux de l'approche contour vu qu'un mauvais choix du seuil en entrée aux algorithmes régions provoque une mauvaise extraction des couronnes. Cette approche considère aussi que les maximums locaux représentent les sommets des couronnes, ce qui n'est pas toujours vrai.

Critère	Approche Contour	Approche Région
Dépendance aux seuils	-	-
Problème de sur-segmentation	-	+
Adaptation aux forêts éparses	+	++
Adaptation aux forêts denses	+	++

TABLE 4.1 – "Comparaison de l'approche contour et de l'approche région"

Perrin[49] et Ericksson[24] [25] réaffirment qu'aucun algorithme ou approche n'est optimal pour l'extraction de tous les types d'arbres. La comparaison entre différents algorithmes a montré que l'algorithme de croissance de régions était le plus efficace dans le cas de forêt dense alors que les autres algorithmes ont tendance à sous estimer le nombre de couronnes.

Le tableau 4.1 présente une comparaison entre l'approche contour et l'approche région.

Pour confirmer notre choix, nous avons réalisé des tests sur quelques images en utilisant deux algorithmes qui sont l'algorithme de suivi des vallées pour l'approche contour et l'algorithme de croissance de régions par mouvement Brownien pour l'approche région.

La figure 4.2 représente le résultat de segmentation sur une image contenant un groupement d'arbres denses, alors que la figure 4.3 représente le résultat de segmentation sur une image contenant un groupement d'arbres épars.

Nous remarquons que les résultats de la segmentation par l'algorithme croissance de région par mouvement Brownien appliqué sur les deux images des figures 4.2 et 4.3 sont les meilleurs. Une analyse visuelle de ces résultats montre une meilleure segmentation de l'algorithme de croissance de région alors que l'algorithme de suivi des vallées provoque des cassures dans les régions et donc une sur-segmentation.

Notre choix est donc confirmé et nous allons utiliser l'algorithme de croissance de régions par mouvement Brownien.




FIGURE 4.2 – Segmentation d'un groupement d'arbres dense  
(a) image initiale; (b) résultat de l'application de l'algorithme de croissance de région; (c) résultat de l'application de l'algorithme de suivi des vallées




FIGURE 4.3 – Segmentation d'un groupement d'arbres épars  
(a) image initiale; (b) résultat de l'application de l'algorithme de croissance de région; (c) résultat de l'application de l'algorithme de suivi des vallées

### 4.3.2 Croissance de région par mouvement brownien

La segmentation en régions de l'image haute résolution relative à la scène d'étude s'est donc basée sur l'algorithme de croissance de région par mouvement Brownien. Nous avons présenté dans le chapitre 3 le principe de cet algorithme. La figure 4.4 illustre l'enchaînement des différentes étapes de l'algorithme et qui aboutit à l'extraction des régions.

L'idée générale de cet algorithme est de trouver en premier lieu les maximums locaux dans l'image, ces maximums locaux seront par hypothèse les sommets des arbres. A partir de chaque maximum local, nous appliquons un mouvement brownien.

Quatre étapes composent cet algorithme.

- **Prétraitement** : Cette étape prépare l'image à l'extraction des couronnes.
- **L'extraction des maximums locaux** : Cette étape permet l'extraction des sommets des couronnes.
- **L'extraction des couronnes d'arbres** : Cette étape permet l'extraction des couronnes mais sans limitation des frontières.
- **La limitation des frontières** : Cette étape permet de limiter les frontières des couronnes extraite dans l'étape précédente.

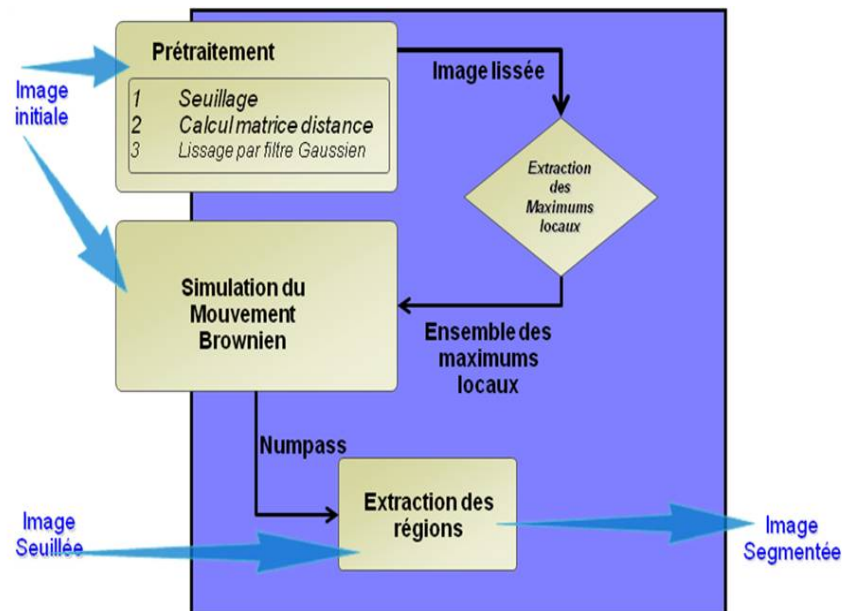


FIGURE 4.4 – Fonctionnement de l'algorithme de croissance de régions par mouvement brownien

### 4.3.3 Automatisation des paramètres de l'algorithme

Les résultats obtenus par l'algorithme de croissance de région par mouvement Brownien dépendent beaucoup de trois paramètres qui sont :



- **Le seuil :** Il permet de filtrer les niveaux de gris de l'image qui ne correspondent pas à la fourchette de niveaux des formations forestières. Il est déduit à partir de l'analyse de l'histogramme de régions recensées.
- **La taille du masque :** C'est la taille de la fenêtre utilisée pour extraire les maximums locaux.
- **Le nombre de pas :** C'est le nombre de pas utilisé par le mouvement Brownien pour dessiner les couronnes d'arbres.

Vu les images sur lesquelles il travaille et leur résolution qui s'élève à 10cm/pixel, Erickson [24] a utilisé des fenêtres et un nombre de pas de taille fixe. Pour notre cas d'application, la résolution des images s'élève à 60cm/pixel. L'utilisation de paramètres fixes ne favorise pas l'obtention d'un résultat satisfaisant vu la variabilité de la taille des couronnes d'arbres existantes.

Nous avons donc opté pour l'utilisation des paramètres dynamiques et qui varient en fonction de l'image à traiter. Pour automatiser le choix de ces paramètres nous proposons de calculer l'aire moyenne des couronnes d'arbres et de se baser sur cette valeur pour attribuer les paramètres à l'algorithme.

Pour calculer l'aire moyenne, nous procédons en quatre étapes :

- **Le seuillage de l'image**
- **Estimation du nombre de couronnes :** Nous estimons le nombre de couronnes d'arbre dans l'image en appliquant un masque afin d'extraire le nombre de maximums locaux.
- **Calcul de l'aire des couronnes :** Nous calculons l'aire totale des couronnes en comptant le nombre de pixels n'appartenant pas à l'arrière plan.
- **Calcul de l'aire moyenne d'une couronne :** L'aire moyenne est donc le ratio entre l'aire totale et le nombre de couronnes.

## 4.4 Caractérisation des régions

Les régions extraites sont caractérisées par des données qui se dégagent à travers la texture et l'information structurelle.

### 4.4.1 La texture

Plusieurs études ont déjà été effectuées dans le domaine de classification par analyse de texture. Franklin et Peddle [29] montrent dans leur travaux que les matrices de cooccurrences du second ordre contiennent une information texturale importante, qui améliore l'identification des classes ayant une hétérogénéité interne et des formes structurales.

#### *Matrice de cooccurrence*

C'est l'approche la plus utilisée pour extraire les caractéristiques de textures, elle informe sur la distribution spatiale des niveaux de gris. Elle permet de déterminer la fréquence d'apparition d'un "motif" formé de deux pixels séparés par une certaine distance  $d$  dans une direction particulière  $\theta$  par rapport à l'horizontale.

Afin de limiter le nombre de calculs, on prend généralement comme valeurs  $0^\circ$ ,  $45^\circ$ ,  $90^\circ$ ,  $135^\circ$ ,  $180^\circ$  et 1 pour la valeur de  $d$ .

La taille de la matrice est  $N_g \times N_g$ , où  $N_g$  correspond au maximum des niveaux de gris de l'image.

On peut définir la matrice de cooccurrence pour une image  $I$  comme suit :

$$P_d(i,j) = | \{ (r,s), (t,v) : I(r,s) = i, I(t,v) = j \} |$$

Avec  $(r,s), (t,v)$  : coordonnées de l'image avec  $(t,v) = (r+d_x, s+d_y)$

$d$  : vecteur de déplacement  $(d_x, d_y)$

$i, j$  : niveau de gris

La figure 4.5 montre le résultat d'extraction de la matrice de cooccurrence à partir de l'image initiale.

Dans notre travail, nous avons calculé la matrice de cooccurrence spécifique à chaque région et donc à chaque couronne d'arbre. Nous avons donc utilisé une caractérisation de la globalité de la texture.

#### *Caractéristiques de Haralick*

Pour pouvoir extraire les attributs texturaux de la matrice de cooccurrence, on doit disposer d'un ensemble d'indices. Haralick [39] propose 14 indices descriptifs




FIGURE 4.5 – Matrice de cooccurrence

de la texture, ils contiennent des informations sur la finesse, la directionnalité et la granularité de la texture. Pour une texture grossière, les valeurs de la matrice sont concentrées sur la diagonale principale. Tandis que, pour une texture fine, les valeurs de la matrice sont dispersées. En effet, pour une telle texture il existe beaucoup de transitions de niveaux de gris.

– **La moyenne**  $MOY = \sum_i \sum_j p(i, j)$  (4.1)

Où  $p(i, j)$  correspond aux éléments de la matrice de cooccurrence ; c'est à dire à la probabilité de passer d'un pixel de niveau de gris  $i$  à un pixel de niveau de gris  $j$ .

– **La variance**  $VAR = \sum_i \sum_j (i - MOY)^2 p(i, j)$  (4.2)

Elle caractérise la distribution des niveaux de gris autour de la valeur moyenne  $M$  calculée précédemment.

– **L'énergie**  $E = \sum_{i,j} (p(i, j))^2$  (4.3)

Ce paramètre mesure l'homogénéité de l'image. L'énergie a une valeur d'autant plus faible qu'il y a peu de zones homogènes : dans ce cas, il existe beaucoup de transitions de niveaux de gris.

Les quatre paramètres suivants sont les plus souvent utilisés :

– **Le contraste**  $\text{CONT} = \sum_i \sum_j (i - j)^2 p(i, j)$  (4.4)

Ce paramètre mesure les variations locales des niveaux de gris. Si elles sont importantes (c'est à dire s'il existe peu de régions homogènes), alors le contraste sera élevé. Ce paramètre permet aussi de caractériser la dispersion des valeurs de la matrice par rapport à sa diagonale principale (figure 4.6).



FIGURE 4.6 – Illustration du contraste sur deux textures de Brodatz différentes

L'image de droite possède plus de transition que l'image de gauche et donc moins de régions homogènes. Son contraste est moins élevé.

– **L'entropie**  $\text{ENT} = - \sum_i \sum_j p(i, j) \log p(i, j)$  (4.5)

mesure la complexité de l'image. Lorsque les valeurs de la matrice sont presque toutes égales, l'entropie est élevée. Elle permet de caractériser le degré de granulation de l'image. Plus l'entropie est élevée et plus la granulation est grossière.




FIGURE 4.7 – Illustration de l'entropie

Dans la figure 4.7, la texture de l'image de gauche semble moins lisse que celle de droite.

– **L'homogénéité**  $\text{HOM} = \sum_{i,j} \frac{1}{1+(i-j)^2} p(i, j)$  (4.6)

Ce paramètre a un comportement inverse du contraste. Plus la texture possède de régions homogènes et plus le paramètre est élevé.




FIGURE 4.8 – Illustration de l'homogénéité

Dans la figure 4.8, la texture de gauche possède plus de régions homogènes que celle de droite d'où un indice d'homogénéité plus élevé.

#### 4.4.2 Mesures et Indices de formes

Les caractéristiques structurelles que nous utilisons pour caractériser la forme des régions et donc des couronnes d'arbres sont les mesures et les indices de formes. Comme défini dans le chapitre 2, les indices de formes sont tout paramètre, coefficient ou combinaison de coefficients permettant de donner des renseignements chiffrés sur la forme de l'objet. Les mesures sont toute valeur ou ensemble de valeurs numériques mesurées sur la forme.

Nous présentons dans la suite quelques mesures et indices de formes utilisées dans notre modèle.

- **Aire** : représente le nombre de pixels de la région.
- **Diamètre** : longueur du plus grand segment inclus dans la forme.
- **Diamètres de Ferret** : mesure une taille dans une direction  $\alpha$  donnée (figure 4.9)  
 $DF(\alpha)$  = plus grande distance des points de l'objet à T.
- **Périmètre** : nombre de points du contour
- **Indice de circularité de Gibson** : Cet indice informe sur la circularité des régions  $CSI = 4\pi A/C^2$
- **Indice d'excentricité**  $e = (L^2 - D^2)^{1/2} / L$




FIGURE 4.9 – Diamètre de Ferret

- **Wellipse** : Cet indice nous indique si une région est elliptique ou pas
- $\text{Wellipse} = \pi \text{ Rmin Rmax} / A$

## 4.5 Apprentissage automatique supervisé

La classification d'images peut être considérée comme un problème d'apprentissage où les exemples d'apprentissage sont les images disponibles étiquetées. Constituer un tel échantillon est réalisable par un expert du domaine. Son expérience est ainsi exploitée implicitement. Ceci est illustré dans la figure 4.10.

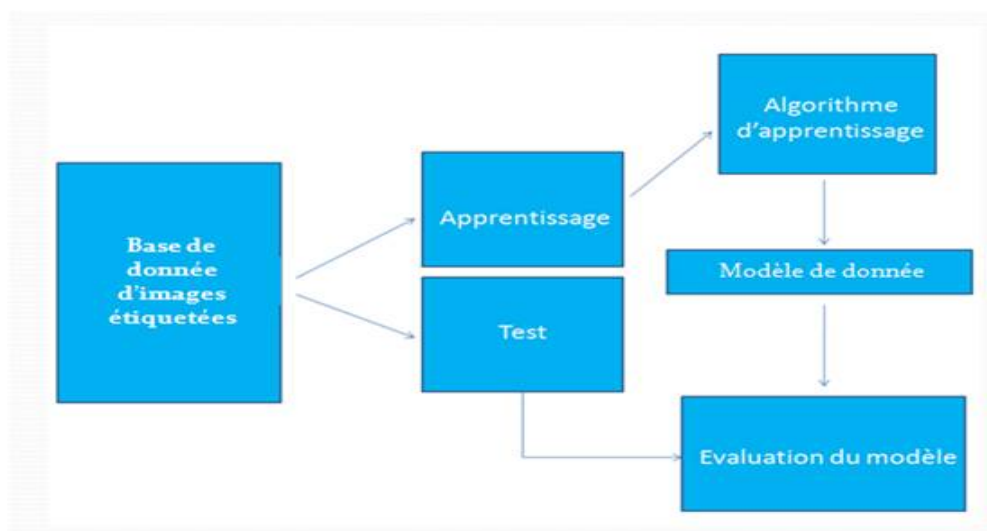


FIGURE 4.10 – L'apprentissage supervisé

Ainsi, pour un problème donné, un modèle de donnée peut être construit de manière automatique à partir d'une base d'images déjà étiquetée. Il aura pour

but de distinguer le mieux possible les différentes classes de l'image à reconnaître. Appliqué à une nouvelle image, il prédit sa classe en fonction de l'information qu'elle contient. Comme pour tout autre problème de classification, il s'agit de modéliser les relations qui existent au sein d'une base de données d'apprentissage entre les variables d'entrée et la variable de sortie et d'appliquer le modèle induit pour la classification de nouvelles instances.

Dans notre travail concernant la forêt, pour instruire le système, encore faut-il avoir une bonne connaissance des terrains observés. Pour cela, il nous faut soit savoir repérer visuellement la nature des cultures, soit disposer d'une vérité terrain. Une vérité terrain est un ensemble de données garanties exactes sur les terrains observés. Elle est réalisée au sol par une observation rapprochée du terrain. C'est un outil pour réaliser un bon apprentissage, ainsi que pour valider une classification. Il est suffisant de disposer d'une vérité terrain sur une portion de l'image où tous les types de terrain sont représentés [51].

Dans notre cas, l'échantillon est représenté par l'image à classer ainsi qu'un inventaire forestier. Ce dernier a été réalisé par des experts qui ont recueilli les informations sur le terrain. L'idée est donc d'utiliser des images caractéristiques pour la représentation d'une classe. Donc à partir de l'inventaire forestier et de l'image sur laquelle on travaille, nous allons construire une base d'apprentissage. Chaque classe est représentée par un ensemble de fenêtres que nous extrayons à partir de l'image.

Pour chaque fenêtre, nous extrayons les couronnes d'arbres à l'aide d'un algorithme de segmentation. Cet algorithme est l'algorithme de croissance de régions par mouvement Brownien. À partir des couronnes extraites, nous calculons un ensemble de caractéristiques texturales et structurelles de chaque région. La base d'apprentissage est alors l'ensemble des caractéristiques calculées à partir des régions extraites pour chaque classe.

## 4.6 Classification des images

Après avoir utilisé l'algorithme de croissance de régions par mouvement brownien pour l'extraction des régions dans l'image et après avoir procédé à la phase d'ap-

prentissage. Nous abordons maintenant la phase de classification. Le choix du classifieur s'est porté sur le classifieur par maximum de vraisemblance. Le choix s'est fait sur ce classifieur grâce à sa rapidité et de son efficacité [46]. Vu l'utilisation des matrices de cooccurrences et son coût élevé en temps d'exécution, notre recherche s'est alors orientée vers un classifieur qui peut nous procurer vitesse et efficacité. D'où le choix du classifieur par maximum de vraisemblance.

Une fois le classifieur choisi, il s'agit d'intégrer les informations et les connaissances structurelles. Les informations structurelles représentées par les indices de forme et les mesures vont être introduites dans le vecteur caractéristique. Nous représentons les connaissances structurelles par les relations spatiales et nous les intégrons à la fin du processus de classification pour l'améliorer.

#### 4.6.1 Classifieur par maximum de vraisemblance

La méthode de classification par maximum de vraisemblance réalise, par l'usage des probabilités et des données de vérité de terrain, une classification plus souple que les méthodes non supervisées qui donne sur des images où les classes sont bien distinctes et où les effectifs par classe sont connus au préalable. Cette technique repose sur les probabilités et s'appuie sur le postulat de la distribution gaussienne des valeurs de l'image. Le principe de la méthode, repose sur la connaissance des paramètres statistiques des classes (vecteurs moyens et matrice de covariance) obtenus à partir des échantillons d'entraînements. La probabilité à priori de chacune des classes est estimée à partir de l'effectif en région de chacune des classes, la probabilité d'appartenance de chaque région aux différentes classes peut être calculée. L'algorithme de classification par maximum de vraisemblance prend en considération la covariance des classes lors de l'affectation des régions. Il définit des contours de forme ellipsoïdale dans l'espace des caractéristiques qui maximise la chance de bonne classification. Le critère de décision est le maximum de probabilité conditionnelle qu'une région appartient à chacune des classes calculées. La région est ensuite affectée à la classe pour laquelle la probabilité d'appartenance est plus élevée. Sachant que  $P_c(X)$  représente la probabilité que la région  $X$  appartienne à la classe  $C$ . La région  $X$  est affectée à la classe  $C$  si :

$$P_c(X) = \text{Max}(P_j(X)) \quad j=1 \dots n \quad (n \text{ est le nombre de classes}).$$



**Algorithme :**

```

1  pour chaque Région X faire
2      pour ( $k=1 ; k \leq n ; k++$ ) faire
3           $f_k(X)$  = Probabilité d'appartenance de X à la classe k;
4      fin
5          // On détermine la classe où elle comporte la grande probabilité
           d'appartenance de X
            $P_c(X) = \text{MAX}(f_k(X))$ ;
6      // Affecter X à la classe  $C_k$   $C \leftarrow C_k$ ;
7  fin

```

**Algorithme 1 :** Algorithme Maximum de Vraisemblance

Avec  $P_c(X) = (1/(2\pi)n/2\|V_c\|) \times \exp(-1/2(X - U_c)^T V_c^{-1}(X - U_c))$  (4.7)

$V_c$  la matrice de covariance de la classe C

$\|V_c\|$  représentant le déterminant de la matrice de covariance

$U_c$  la moyenne de la signature de la classe C

T la fonction transposée

## 4.6.2 Intégration de l'information et des connaissances structurelles

### *Intégration des informations structurelles*

Les informations structurelles que nous utilisons dans notre système sont les indices de forme et les mesures précédemment présentées. Ces informations présentent une caractérisation numérique et calculable des informations géométriques et des informations concernant la forme des régions. Nous intégrons alors les indices de formes et les mesures dans la phase d'extraction des caractéristiques. (figure 4.11). Pour chaque région, nous extrayons les mesures et les indices de formes déjà décrites dans le deuxième chapitre. À partir de ces caractéristiques additionnées aux caractéristiques texturales nous construisons le vecteur caractéristique spécifique à la région en question. Le classifieur a alors comme entrée le modèle de données extrait dans la phase d'apprentissage ainsi que le vecteur caractéristique de la région à classer.

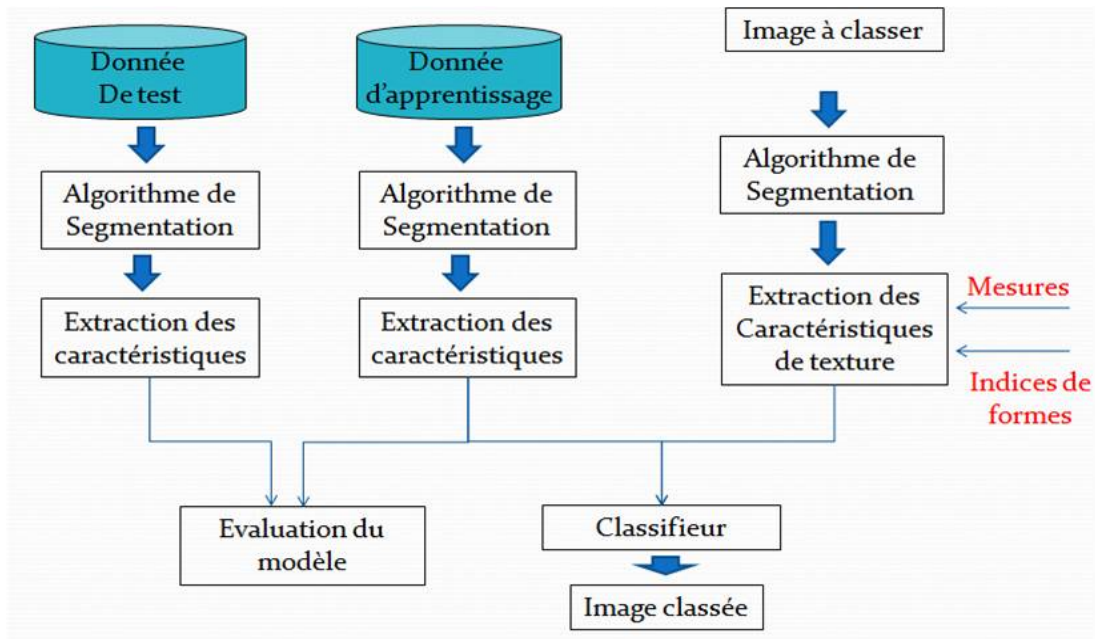


FIGURE 4.11 – Intégration de l'information structurale dans le vecteur Caractéristique

### *Amélioration de la classification en utilisant les connaissances structurales*

Pour représenter des connaissances expertes, beaucoup de méthodes ont été présentées dans la littérature. La façon de représenter des connaissances expertes dépend du contexte de l'image à traiter, des données exogènes disponibles et des connaissances elles-mêmes.

Une première approche est d'utiliser un système d'inférence floue, l'information structurale sera alors décomposée en deux niveaux.

Niveau 1 : "Si (classe  $k$ ), alors ( $CSE_1$ ) et ... et ( $CSE_j$ ) et ... et ( $CSE_M$ )".

Niveau 2 : " Si ( $CSE_j$ ), alors ( $V_1^j$  est  $A_1^j$ ) et ... et ( $V_i^j$  est  $A_i^j$ )".

La partie conclusion du Niveau 1 de la règle se compose de connaissances structurales élémentaires  $CSE_j$  unies par des "et" (et éventuellement par des "ou") logiques. Dans le Niveau 2, chaque  $CSE_j$  est exprimée par l'intermédiaire de variables mesurables  $V_1^j$  et de sous-ensembles flous  $A_1^j$  [62].

Le calcul d'un degré d'adéquation à partir de ces règles va permettre de connaître le degré de vérité de la règle par apport à la région en question.

Une autre approche est l'approche qui utilise des modèles de références comme celles décrites dans le chapitre trois.

Une dernière approche est l'approche utilisant les graphes. Pour cette approche, le degré d'adéquation de la région considérée à la connaissance peut être un degré de correspondance entre la région et la référence [16] [44] [48].

Dans notre travail, nous introduisons des connaissances concernant les relations spatiales après la classification initiale (figure 4.12). Nous nous basons sur l'inventaire forestier comme source d'information et nous en extrayons des informations concernant les relations d'adjacences entre les arbres.

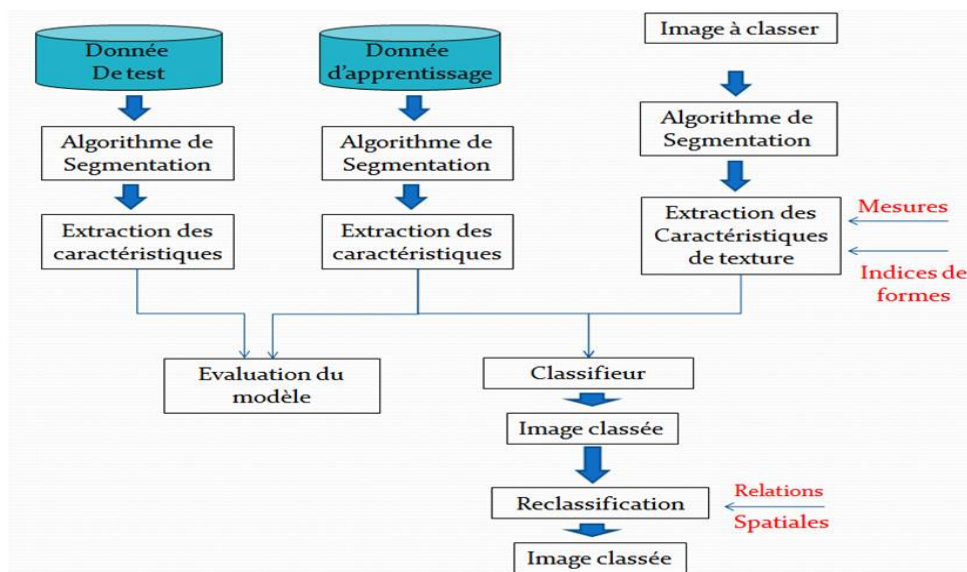


FIGURE 4.12 – Intégration de la connaissance structurelle dans le système

La conclusion que nous pouvons tirer en étudiant l'inventaire est que certains types d'arbres ne peuvent pas cohabiter ensemble dans un même groupement. En effet, nous avons remarqué que seulement deux types d'arbres parmi les quatre existants dans l'inventaire peuvent cohabiter dans le même groupement. Les autres types d'arbres ne peuvent pas être identifiés dans le même groupement. Deux cas se présentent alors, le premier cas est celui d'une image contenant une frontière entre deux groupements d'arbres comme illustré dans la figure 4.13 (a). Le deuxième cas est celui d'une image contenant deux groupements d'arbre mais qui ne sont pas séparés par une frontière comme c'est le cas de la figure 4.13 (b). Pour le premier cas, nous identifions une frontière et qui représente une zone ne

contenant pas d'arbre et qui allonge deux zones qui en contiennent. Pour le second cas, nous chercherons alors une variation brusque de niveau de gris et donc un contour entre deux groupements d'arbres.




FIGURE 4.13 – Image contenant une frontière entre deux groupements d'arbres  
(a) groupements séparés avec une frontière; (b) groupements sans frontière

Si nous ne nous trouvons pas dans l'un de ces deux cas et que nous détectons deux types d'arbres qui ne peuvent pas cohabiter dans un même groupement nous aurons alors à trouver le type d'arbre intrus.

Le problème ici est de trouver lequel des types d'arbres est l'intrus. Pour cela, nous proposons de voir le nombre de représentants de chacune des espèces d'arbres présents dans l'image et de les comparer. Si la différence d'apparition entre les deux types d'arbres dépasse un certain seuil  $\alpha$ , nous changeons alors la classe des arbres mal classés.

Sachant que nous ne disposons pas de connaissances expertes concernant la forme des arbres, nous ne pouvons pas traiter ce cas mais nous proposons l'utilisation d'un système d'inférence floue [62] basé sur les indices de formes et les mesures. En effet, la valeur de l'indice de forme indique sur la forme de la région qui lui équivaut par exemple si nous voulons savoir si une région est circulaire ou pas nous utilisons l'indice de circularité de Gibson(CSI) ou le déficit isométrique qui

informent sur la circularité de la région. Plus l'indice s'approche de 1 plus la forme est circulaire et plus il s'approche de 0 plus elle est linéaire dans ce cas la valeur du degré d'adéquation est celle de l'indice de forme.

Sachant qu'un indice de forme est construit à partir d'une égalité (ou inégalité) propre à la forme que nous souhaitons caractériser, tout type de forme peut alors être caractérisé par un indice de forme.

Prenons par exemple la connaissance suivante : Le chêne zen est de forme circulaire et de grande taille. Nous transformons cette connaissance en deux niveaux : Niveau 1 : "Si (chêne zen), alors ( $CSE_1$  : Forme circulaire) et ( $CSE_2$  : Taille grande) ".

Niveau 2 : " Si (Forme circulaire), alors (déficit isométrique est proche de 1) et (CSI est proche de 1).

Si (taille grande), alors ( $aire \geq 250$  pixels)".

Le degré d'adéquation final sera calculé en fonction des degrés d'adéquation des deux niveaux.

## 4.7 Conclusion

Dans ce chapitre, nous avons présenté notre approche. Le but de notre travail est d'extraire puis de classer les couronnes d'arbres et cela en intégrant les informations et les connaissances structurelles dans le processus de classification. Dans le chapitre suivant nous présentons nos résultats expérimentaux pour illustrer l'efficacité de notre approche.



## Chapitre 5

# Expérimentation et évaluation

## 5.1 Introduction

Ce chapitre traite les résultats expérimentaux relatifs à notre approche.

Nous commençons tout d'abord par présenter l'image sur laquelle nous avons travaillé. Nous présentons ensuite quelques résultats de la segmentation qui nous a permis d'extraire les couronnes d'arbres.

Nous présenterons ensuite l'inventaire forestier que nous avons utilisé pour la phase d'apprentissage.

Pour illustrer la pertinence de notre approche, nous présentons la classification sans et avec les informations et connaissances structurelles.

## 5.2 Présentation de l'image

L'image sur laquelle nous avons travaillé est une image très haute résolution QuickBird proche infra rouge (Pir) ayant pour résolution 0.6m/pixel. Cette image représente la zone forestière d'Ain Drahim, gouvernorat de Jendouba.

La figure 5.1 présente des échantillons des différentes classes de l'image en question :

- La figure 5.1 (a) est un groupement de chêne zen épars.
- La figure 5.1 (b) quant à elle représente un groupement de chêne zen dense.
- La figure 5.1 (c) est un groupement de chêne liège.
- La figure 5.1 (d) est un groupement mixte contenant des chênes lièges et des chênes zen.
- Les figures 5.1 (e) et 5.1 (f) représentent respectivement un groupement d'arboretum et de forêt résineux.






FIGURE 5.1 – Images satellitaires haute résolution : Forêt de Jendouba

## 5.3 Croissance de région par mouvement Brownien

### 5.3.1 Paramétrisation de l'algorithme

Nous évaluons la dépendance de l'algorithme croissance de région par mouvement Brownien, auquel nous donnons l'abréviation CRMB, aux trois paramètres qui sont :

- Le seuil,
- La taille de la fenêtre d'extraction des maximums locaux,

- Le nombre de pas nécessaire à la simulation du mouvement Brownien

La figure 5.2 et la figure 5.3 montrent que le choix de la fenêtre est primordial pour l'extraction des maximums locaux et qu'il diffère d'une image à l'autre. Dans la figure 5.2 qui représente un groupement épars de chêne zen, nous avons remarqué que plus la taille de la fenêtre est grande plus l'identification des maximums locaux est précise. En effet, les deux images 5.2 (a) et 5.2 (b) sont le résultat de l'application d'un masque  $3 \times 3$  pour la première et d'un masque  $5 \times 5$  pour la deuxième. Nous remarquons dans les deux images une explosion dans le nombre de maximums locaux. Ceci provoque une sur-estimation du nombre des couronnes d'arbres. Les points blancs dans l'image représentent les maximums locaux.

Pour les images 5.2 (c) et 5.2 (d), nous avons utilisé les masques  $11 \times 11$  et  $13 \times 13$ . Nous constatons que l'extraction des maximums locaux est réussie et que la plus part des points représentent réellement les arbres. Cependant, il reste quelques anomalies puisque quelques sommets d'arbres n'ont pas été détectés.




FIGURE 5.2 – Extraction des maximums locaux pour une forêt épars  
 (a) fenêtre de taille  $3 \times 3$ ; (b) fenêtre de taille  $5 \times 5$ ; (c) fenêtre de taille  $11 \times 11$ ; (d) fenêtre de taille  $13 \times 13$

Pour la figure 5.3 (a), c'est un groupement d'arboretum dense. Les deux images 5.3 (b) et 5.3 (c) donnent un meilleur résultat et sont dûs à l'application d'un masque  $3 \times 3$  et  $5 \times 5$ . Pour les images 5.3 (d) et 5.3 (e), nous constatons que beaucoup de sommets d'arbre n'ont pas été détectés.




FIGURE 5.3 – Extraction des maximums locaux pour une forêt dense  
(a) image initiale; (b) fenêtre de taille  $3 \times 3$ ; (c) fenêtre de taille  $5 \times 5$ ; (d) fenêtre de taille  $11 \times 11$ ; (e) fenêtre de taille  $13 \times 13$

La conclusion que nous pouvons tirer de ces deux figures est que c'est la taille des arbres qui nous dicte la taille de la fenêtre à utiliser.

Pour la figure 5.2, les chênes zen sont de grande taille par apport aux arboretums de la figure 5.3 d'où le fait d'avoir un meilleur résultat avec des grandes fenêtres. Une sur-estimation de la taille des fenêtres provoque alors une perte d'information concrétisée par un manque de certains maximums locaux, donc une sous estimation du nombre de couronnes d'arbres.

Une sous-estimation de la taille des fenêtres provoque quant à elle une sur-estimation du nombre de maximums locaux.

D'après les différents tests réalisés, nous pouvons dire que le choix de la fenêtre dépend en premier lieu de la taille des arbres qui se trouvent dans l'image. En effet, plus la taille des couronnes est grande plus la taille de la fenêtre choisie doit être grande.

Le deuxième paramètre qui entre en jeu dans la segmentation est la valeur du seuil. Le rôle de ce seuil est d'éviter le bruit dans l'image. Dans notre cas, nous considérons comme bruit tous ce qui n'est pas arbres.

La figure 5.4 (a) représente le résultat du seuillage de la figure 5.4 (e) avec un seuil de 0,7 alors que La figure 5.4 (b) est le résultat final de la segmentation. Les figure 5.4 (c) et figure 5.4 (d) quant à elles correspondent au seuil 0,5. Nous constatons qu'avec le seuil 0,7, nous avons évité la majorité du bruit ce qui a permis une bonne segmentation. Pour le seuil 0,5, une grosse partie du bruit n'a pas été enlevée ce qui a engendré une mauvaise segmentation puisque une partie de bruit a été traitée comme étant des couronnes d'arbres et des couronnes ont été déformées puisqu'elles ont été fusionnées avec le bruit lors de la segmentation.




FIGURE 5.4 – Résultats de segmentation avec l'algorithme de croissance de régions par mouvement Brownien avec deux seuils différents :

(a) image seuillée avec le seuil 0,7 ; (b) résultat de la segmentation avec le seuil 0,7 ; (c) image seuillée avec le seuil 0,5 ; (d) résultat de la segmentation avec le seuil 0,5 ; (e) image initiale

Le dernier paramètre de l'algorithme CRMB est le nombre de pas du mouvement Brownien. La figure 5.5 montre qu'un mauvais choix de ce paramètre provoque une déformation des couronnes d'arbres. En effet, la figure 5.5 (c) montre des couronnes déformées due à une sous-estimation du nombre de pas lors de la segmentation de la figure 5.5 (a) alors que pour la figure 5.5 (b) les couronnes sont très bien détectées. Une sous-estimation du nombre de pas peut provoquer une déformation des couronnes vu que la particule ne va pas atteindre tous les points de la couronne. Une sur-estimation quant à elle peut provoquer la fusion de certains couronnes ou bien la déformation de ces dernières.

Le choix du seuil se base alors sur la taille des arbres et sur leur densité.




FIGURE 5.5 – Segmentation avec deux nombre de pas différents

(a) image initiale ; (b) résultat de la segmentation avec un nombre de pas égal à 100000 ; (c) résultat de la segmentation avec un nombre de pas égal à 1000

### 5.3.2 Extraction des couronnes d'arbres

Les figures 5.6, 5.7, 5.8, 5.9 et 5.10 présentent la segmentation des différents types de groupement d'arbres présents dans notre image. Malgré les différentes

caractéristiques entre ces images, nous avons obtenu de bons résultats lors de la segmentation. Pour chaque figure, nous avons présenté l'image initiale (a), l'image ayant subi une égalisation de l'histogramme pour mieux visualiser les couronnes (b), l'image segmentée (c), les contours des segments (d) et enfin la superposition des contours avec l'image initiale pour évaluer la segmentation(e)(f).

Dans les figures 5.6 et 5.7, nous présentons la segmentation d'un groupement d'arbre chêne zen. La première figure (figure 5.6) est celle d'un groupement dense, nous remarquons alors que les couronnes sont bien détectées et que les couronnes ne sont pas déformées.




FIGURE 5.6 – Segmentation d'un groupement de chêne zen dense  
(a) image initiale; (b) image ayant subi une égalisation de l'histogramme; (c) résultat de la segmentation; (d) contour des régions; (e)(f) superposition des contours sur l'image initiale



La deuxième figure (figure 5.7) est quand à elle celle d'un groupement d'arbres épars, le résultat est excellent et les arbres sont très bien délimités.




FIGURE 5.7 – Segmentation d'un groupement de chêne zen épars  
(a) image initiale ; (b) image ayant subi une égalisation de l'histogramme ; (c) résultat de la segmentation ; (d) contour des régions ; (e)(f) superposition des contours sur l'image initiale




FIGURE 5.8 – Segmentation d'un groupement de chêne liège  
(a) image initiale ; (b) image ayant subi une égalisation de l'histogramme ; (c) résultat de la segmentation ; (d) contour des régions ; (e)(f) superposition des contours sur l'image initiale

La figure 5.8 est celle d'un groupement de chêne liège. Les couronnes sont bien extraites mais quelques unes sont un peu déformées.




FIGURE 5.9 – Segmentation d'un groupement d'arboretum

(a) image initiale ; (b) image ayant subi une égalisation de l'histogramme ; (c) résultat de la segmentation ; (d) contour des régions ; (e)(f) superposition des contours sur l'image initiale




FIGURE 5.10 – Segmentation d'un groupement de forêt résineux

(a) image initiale ; (b) image ayant subi une égalisation de l'histogramme ; (c) résultat de la segmentation ; (d) contour des régions ; (e)(f) superposition des contours sur l'image initiale



La figure 5.9 représente un groupement d'arboretum. La segmentation donne de très bons résultats et les couronnes ne subissent pas de déformation.

La Figure 5.10 est celle d'un groupement de forêts résineux et c'est là où on rencontre le plus de problème vu qu'il existe des régions qui ont été déformées et d'autres qui ont été fusionnées. Mais le résultat reste acceptable.

## 5.4 Apprentissage

La phase d'apprentissage est une phase extrêmement importante de notre système. Notre apprentissage va se baser sur l'inventaire forestier de la Figure 5.11. Les fenêtres de l'image que nous utilisons sont extraites en superposant l'inventaire forestier sur notre image comme illustré dans la figure 5.12. Et pour chaque classe nous extrayons quelques fenêtres.

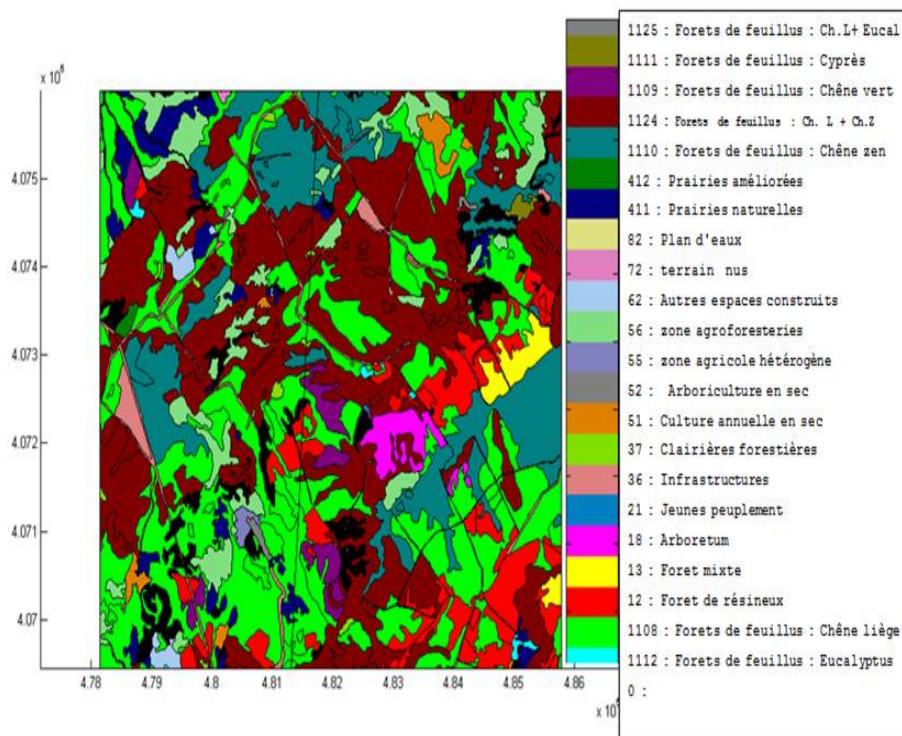


FIGURE 5.11 – Inventaire forestier



FIGURE 5.12 – Inventaire forestier superposé sur l'image

## 5.5 Caractérisation des régions

Le modèle de caractérisation des régions va être composé d'un ensemble de caractéristiques texturales et d'un ensemble de caractéristiques structurales. Pour avoir le modèle le plus discriminant et qui nous permet d'optimiser notre classification, nous devons construire une combinaison linéaire des différents caractéristiques et de montrer la pertinence de ce modèle.

Pour se faire, nous avons réalisé un ensemble de tests en variant le nombre et la combinaison des caractéristiques utilisées lors de la phase d'apprentissage. L'ensemble des caractéristiques retenu est celui qui maximise le pourcentage de bonne classification.

La figure 5.13 montre que la meilleure combinaison possible est celle qui combine entre sept caractéristiques texturales et cinq caractéristiques structurales. En effet, le pourcentage de bonne classification a atteint son maximum pour arriver à 79.35 % pour la configuration que nous venons de citer.




FIGURE 5.13 – Courbe représentant l'évolution de la classification en fonction des caractéristiques structurelle

## 5.6 Validation de la classification

Pour évaluer l'exactitude de la classification, nous extrayons quelques échantillons de vérification à partir desquelles on calcule une matrice de confusion. Pour chaque classe, une ou plusieurs zones de vérification sont délinéées. L'exactitude de la classification, pour une classe donnée, correspond à la proportion des arbres, à l'intérieur de la zone de vérification correspondante, qui sont attribués à la bonne classe.

Nous présentons deux matrices de confusion afin de montrer l'apport de l'information structurelle dans la classification. Le tableau 5.1 représente la matrice de confusion de la classification de l'image en utilisant uniquement les caractéristiques texturales. Le pourcentage de bonne classification qui atteint les 77.75 %.

Le tableau 5.2 quant à lui représente la matrice de confusion correspondante à

	Espèce			
	Arboretum	Forêt résineux	Chêne liège	Chêne zen
Nombre de couronnes	235	148	465	435
Espèce détectée				
Arboretum	168 (71,49 %)	2 (1,35 %)	0 (0,0 %)	0 (0,0 %)
Forêt résineux	67 (28,51 %)	146 (98,65 %)	16 (3,44 %)	0 (0,0 %)
Chêne liège	0 (0,0 %)	0 (0,0 %)	360 (77,42 %)	159 (36,55 %)
Chêne zen	0 (0,0 %)	0 (0,0 %)	89 (19,14 %)	276 (63,45 %)

Tableau 5.1 Matrice de confusion résultant de l'utilisation de l'information texturale uniquement avec une exactitude moyenne de 77.75%

la classification qui intègre l'information structurale. Le pourcentage de bonne classification qui atteint les 79.35 %. Nous constatons que le pourcentage de bonne classification a été amélioré avec l'intégration de l'information structurale. L'amélioration est de l'ordre de 1.6 %. Or cette augmentation ne touche pas à toutes les classes. En effet, nous remarquons que l'amélioration n'a affecté que deux classes qui sont la classe arboretum et la classe chêne zen.

	Espèce			
	Arboretum	Forêt résineux	Chêne liège	Chêne zen
Nombre de couronnes	235	148	465	435
Espèce détectée				
Arboretum	201 (85,53 %)	22 (14,86 %)	0 (0,0 %)	0 (0,0 %)
Forêt résineux	34 (14,47 %)	126 (85,14 %)	50 (10,75 %)	2 (0,46 %)
Chêne liège	0 (0,0 %)	0 (0,0 %)	350 (75,26 %)	122 (28,05 %)
Chêne zen	0 (0,0 %)	0 (0,0 %)	65 (13,99 %)	311 (71,49 %)

Tableau 5.2 Matrice de confusion résultant de l'utilisation de l'information texturale et structurale avec une exactitude moyenne de 79.35%

Pour la première classe, l'augmentation atteint les 14.4% alors que pour la deuxième elle atteint les 8.04 %. Pour les classes chêne liège et forêt résineux, nous avons

constaté une dégradation au niveau de la classification. La classe forêt résineux a perdu 13.41 % de bonne classification alors que la classe chêne liège a perdu quant à elle 2.18 %. Ce qui implique que c'est la classe forêt résineux qui influe sur la moyenne général. Ceci s'explique par le fait que certaines régions de cette classe coïncide avec les régions de la classe arboretum dans leurs caractéristiques structurelles. Donc en intégrant les informations structurelles dans le vecteur caractéristiques, le pourcentage de bonne classification de cette classe s'est détérioré et une partie des régions qui été assignée à la classe forêt résineux ont été affecté à la classe arboretum.

La figure 5.14 représente la classification d'une image mixte qui contient des chênes lièges et des chênes zen. Dans l'inventaire, cette image appartient à une classe commune qui contient les deux types d'arbres vu que la classification dans l'inventaire ne se fait pas à l'arbre prêt. Nous avons donc permis d'éclater cette classe en classant chaque région et donc chaque arbre séparément ce qui donne le résultat illustré dans la figure 5.14 (d).

## 5.7 L'apport des connaissances structurelles dans la classification

Pour essayer d'améliorer encore plus la classification nous avons introduit des connaissances structurelles qui se basent sur les relations d'adjacence entre les régions.

La règle que nous avons utilisée se base sur l'hypothèse que seul les chênes zen et les chênes liège peuvent se regrouper dans un même groupement d'arbre. Donc la seule possibilité de voir deux types d'arbre se trouver dans la même image est d'avoir deux groupements différents et donc d'avoir une frontière entre ces deux groupements.

Dans la figure 5.15 nous avons 3 espèces qui apparaissent dans l'image et qui sont les chênes liège avec un taux d'apparition de 75.92 %, les chênes zen avec 11.11 % et finalement les forêts résineux avec 12.96 %. Sachant que l'image ne contient pas de frontière et qu'il n'y a qu'un unique groupement d'arbre, nous pouvons donc utiliser la connaissance experte. Nous prenons comme seuil 50 %, nous ne pouvons donc éliminer une classe que si il existe une autre classe avec laquelle




FIGURE 5.14 – Classification d'une zone mixte

(a) image initiale; (b) image ayant subi une égalisation de l'histogramme; (c) image segmentée; (d) résultat de la classification



elle ne peut pas cohabiter et qui la dépasse en densité dans l'image de 50 %. La figure 5.16 présente le résultat de la reclassification de la figure 5.15 en intégrant les connaissances structurelles.




FIGURE 5.15 – Groupement de forêt chênes liège classé en intégrant les informations structurelles




FIGURE 5.16 – Groupement de forêt chênes liège classé en intégrant les connaissances structurelles

Le tableau 5.3 illustre l'amélioration de la classification après avoir intégré les connaissances structurelles. En effet, le taux de bonne classification augmente de 79.35 % à 84.70 %.

	Espèce			
	Arboretum	Forêt résineux	Chêne liège	Chêne zen
	235	148	465	435
<b>Nombre de couronnes</b>				
<b>Espèce détectée</b>				
Arboretum	220 (93,61 %)	16 (10,81 %)	0 (0,0 %)	0 (0,0 %)
Forêt résineux	15 (6,39 %)	132 (89,19 %)	9 (1,94 %)	0 (0,0 %)
Chêne liège	0 (0,0 %)	0 (0,0 %)	391 (84,07 %)	122 (28,05 %)
Chêne zen	0 (0,0 %)	0 (0,0 %)	65 (13,99 %)	313 (71,95 %)

Tableau 5.3 Matrice de confusion résultant après l'intégration des connaissances structurelles avec une exactitude moyenne de 84.70 %

Donc l'intégration combiné des informations et des connaissances structurelle a permis d'améliorer la classification de 6.95 % en passant de 77.75 % en utilisant uniquement les connaissances texturale à 79.35 en intégrant les informations structurelles pour finalement aboutir à 84.70 % en intégrant les connaissances structurelles.

## 5.8 Conclusion

Dans ce chapitre, nous avons présenté les résultats expérimentaux de notre travail. Nous avons tous d'abord commencé par présenter l'image sur laquelle nous avons travaillé. Nous avons ensuite présenté la paramétrisation de l'algorithme de croissance de région par mouvement brownien qu'on a utilisé pour l'extraction de couronnes d'arbres. Nous avons aussi présenté l'inventaire forestier qui est la base de l'apprentissage. Finalement nous avons démontré l'apport de l'intégration des informations et des connaissances structurelles pour la classification.



# Conclusion

Nous avons été amenés dans le cadre de ce travail à utiliser les informations et les connaissances structurelles pour améliorer le résultat de la classification d'images de télédétection. L'omniprésence de structure et de relations spatiales dans l'image nous a conduits à extraire ces structures et les prendre en considération dans la phase de décision d'affectation en classes.

L'architecture du système que nous avons introduit s'articule sur trois phases de traitement. La première est une phase de segmentation nécessaire à l'extraction des régions. Cette étape nous a conduits à étudier les algorithmes de segmentation en région et plus particulièrement les algorithmes d'extraction de couronnes d'arbres. Nous avons présenté les quatre approches les plus répandues dans la littérature qui sont l'approche par maximums locaux, l'approche région, l'approche objet et l'approche contour. Notre choix a été porté sur l'approche région et plus particulièrement sur l'algorithme de croissance de région par mouvement brownien.

La deuxième phase concerne la caractérisation des régions. Nous avons proposé un modèle composé de caractéristiques texturales et structurelles. Les caractéristiques texturales choisies sont les caractéristiques de Haralick alors que les structures se réfèrent à une combinaison de mesures et d'indices de formes. Le choix des mesures et des indices de formes nous a été dicté par l'absence de connaissances expertes concernant la forme des couronnes.

La troisième phase a été consacrée à classification des couronnes. Une première étape d'apprentissage nous a permis d'avoir une caractérisation de l'ensemble des classes de la scène à traiter. Nous avons ensuite cherché à trouver l'ensemble de caractéristiques les plus discriminantes et qui permettent une meilleure séparation entre les classes. Nous avons cherché à trouver la meilleure combinaison d'indices de formes et de mesures qui minimise le taux de discordance de classification.

L'application de notre système sur une image QuickBird a montré l'importance de l'information structurelle et son apport dans l'amélioration des résultats dégagés par un classifieur basé sur la texture. Cet apport s'explique par la prise en compte de l'information de la forme, de la surface, du périmètre, de l'étendu et de la géométrie de la couronne de manière générale dans la classification, des aspects qu'utilise le photo-interprète dans l'analyse visuelle de la scène.

Comme perspectives nous préconisons l'utilisation des indices de forme et des mesures de la géométrie des objets segmentés dans un système de classification basé sur la fusion de sources d'informations. En effet, l'une des sources additives qui pourrait s'ajouter dans le kit de données pourrait être une cartographie de la géométrie des objets détectés définie par les vecteurs d'informations structurelles.

# Bibliographie

- [1] H. Bendjoudi. Le coefficient de compacité de gravelius : analyse critique d'un indice de forme des bassins versants. *Hydrological Sciences-Journal-des Sciences Hydrologiques*, 47(6), 2002.
- [2] J.C. Bezdek, J. Keller, R. Krisnapuram, and N. R. Pal. *Fuzzy models and algorithms for pattern recognition and image processing*. Kluwer Academic Publishers, Massachusetts, États-Unis, 1999.
- [3] I. Bloch. On fuzzy distances and their use in image processing under imprecision. *Pattern Recognition*, 32(11) :1873–1895, 1999.
- [4] I. Bloch. Mathematical morphology and spatial relationships : Quantitative, semi-quantitative and symbolic settings. *Applying Soft Computing in Defining Spatial Relationships*, pages 63–98, 2002.
- [5] I. Bloch, O. Colliot, and R.M. Cesar. Modélisation de la relation spatiale « entre » pour des objets d'extensions spatiales très différentes. Technical report, 2005.
- [6] B. Bouchon. *La logique floue et ces applications*. Addison Wesley, Paris, 1995.
- [7] B. G. Buchanan and E. H. Shortliffe. *Rule-based expert systems : the MYCIN experiments of the Stanford heuristic programming project*. Addison Wesley, Massachusetts, États Unis, 1984.
- [8] A.P. Carleer. and E. Wolff. Regionbased classification potential for landcover classification with very high spatial resolution satellite data. Technical report, 2006.
- [9] O. Colliot, A.V. Tuzikov, R.M. Cesar, and I. Bloch. Approximate reflectional symmetries of fuzzy objects with an application in model-based object recognition. *Fuzzy Sets and Systems*, 1(147) :141–163, Octobre 2004.
- [10] A. Cornuéjols. Une nouvelle méthode d'apprentissage : Les svm. séparateurs à vaste marge. *Bulletin de l'AFIA*, 51, Juin 2002.
- [11] T. Cover and P. Hart. Nearest neighbor pattern classification. *IEEE Trans. Information Theory*, 13(1) :21–27, 1967.

- 
- [12] K. Crammer and Y. Singer. On the algorithmic implementation of multi-class svms, 2001. JMLR.
  - [13] C. Cristianini and J. Shawe-Taylor. An introduction to support vector machines, 2000. MIT Press Cambridge.
  - [14] B.V. Dasarathy. Nearest neighbor (nn) norms : Nn pattern classification techniques., 1990. IEEE Computer Society Press, Los Alamitos, Californie, États Unis.
  - [15] A. David, A. Traill, M. Keating, I. Altieri, and W. Lowell Maughan. Abnormalities of dynamic ventricular shape change in patients with aortic and mitral valvular regurgitation : Assessment by fourier shape analysis and global geometric indexes. *Circulation Research*, 62(1) :127–138, 1988.
  - [16] A. Deruyver and Y. Hodé. Constraint satisfaction problem with bilevel constraint : application to interpretation of over-segmented images. *Artificial Intelligence*, 93 :321–335, 1997.
  - [17] Z. Ben Dhiaf, J. Desachy, and A. Hamouda. Information sources fusion approach in forest stand classification. SPIE, conference on.
  - [18] Z. Ben Dhiaf, J. Desachy, and A. Hamouda. Système de classification basée sur la théorie des fonctions de croyance. 22-26 Mai 2007. Taima’07, Hammamet, Tunisie.
  - [19] Z. Ben Dhiaf, J. Desachy, and A. Hamouda. Management of the conflict between information sources in a fusion process : Application in forest cartography. 9-11th July, 2008.. ISIVC’2008, 4th International Symposium on Image/Video Communications over fixed and mobile networks, Bilbao, Spain.
  - [20] E. Diday, J. Lemaire, and J. F. Pouget. *Éléments d’analyse de données*. Dunod, Paris, France, 1982.
  - [21] R. O. Duda and Hart P. E. *Pattern Classification and Scene Analysis*. John Wiley and Sons, Chichester, Royaume Uni, 1973.
  - [22] M. Erickson. Species classification of individually segmented tree crowns in high-resolution aerial images using radiometric and morphologic image measures. *Remote Sensing of Environment*, 91 :469–477, 2004.
  - [23] M. Erickson and K. Vestlund. Finding tree-stems in laser images of young mixed stands to perform selective cleaning. *Proc. of the ScandLaser Scientific Workshop on Airborne Laser Scanning of Forests*, pages 244–250, 2003.
  - [24] M. Eriksson. Comparison of three individual tree crown detection methods. *Machine Vision and Applications*, 16(4) :258–265, 2005.

- [25] M. Eriksson, G. Perrin, X. Descombes, and J. Zerubia. A comparative study of three methods for identifying individual tree crowns in aerial images covering different types of forests., 2006. Proc. of International Society for Photogrammetry and Remote Sensing (ISPRS) Symposium Commission 1, Marne La Vallée, France.
- [26] E. Fix and Jr. J. Hodges. Discriminatory analysis : non-parametric discrimination : Consistency properties. Technical report, 1951.
- [27] G. Forestier. *Classification collaborative et intégration de connaissances*. Mémoire de Master, Université Louis Pasteur Strasbourg, France, 2007.
- [28] E. Forgý. Cluster analysis of multivariate data : efficiency versus interpretability of classification. *Biometrics num 21*, 21 :768–780, 1965.
- [29] S.E. Franklin and R.D. Peddle. Spectral texture for improved class discrimination in complex terrain. *International journal of Remote Sensing*, 10 :264–323, 1989.
- [30] I. Gath and A. B. Geva. Unsupervised optimal fuzzy clustering. *IEEE Trans. Pattern Analysis and Machine Intelligence*, 11(7) :773–781, 1989.
- [31] G. Giraudon, P. Garnesson, and P. Montésinon. Messie : un système multi-spécialistes en vision. application à l’interprétation en imagerie aérienne. *Traitement du Signal*, 9(5), 1992.
- [32] F.A. Gougeon. A crown-following approach to the automatic delineation of individual tree crowns in high spatial resolution aerial images. *Journal canadien de télédétection*, 21(3) :274–284, 1995.
- [33] F.A. Gougeon and D.G. Leckie. Extraction d’information forestière à partir d’image à haute résolution spatiale en utilisant une méthode de reconnaissance individuelle des cimes d’arbres. Technical report, 2003.
- [34] F.A. Gougeon, D.G. Leckie, I. Scott, and D. Paradine. Individual tree crown species recognition : the nahmint study. *D.A. Hill and D.G*, pages 209–223, 1999.
- [35] M. Grabisch and J.M. Nicolas. Classification by fuzzy integral : performance and tests. *Fuzzy Sets and Systems*, 65 :255–271, 1994.
- [36] Y. Guermeur. *SVM Multiclasses, Théorie et Applications*. Habilitation à Diriger des Recherches, Ecole doctorale IAEM Lorraine, France, 2007.
- [37] C. M. Gurney and J. R. G. Townsend. The use of contextual information in the classification of remotely sensed data. *Photogrammetric Engineering and Remote Sensing*, 49(1) :55–64, 1983.

- 
- [38] E. E. Gustafson and W. Lessel. Fuzzy clustering with a fuzzy covariance matrix., 1979. Dans Proc. IEEE Conf. Decision and Control, San Diego, Californie, États Unis.
- [39] R.M. Haralick. Statistical and structural approaches to texture. *PROCEEDINGS OF THE IEEE*, 67(5) :Mai 1979.
- [40] S. Herlidou. *Caractérisation tissulaire en imagerie par RMN par l'analyse de texture : Etude du tissu musculaire et de tumeurs intracrâniennes*. Thèse de doctorat, L'université de Rennes 1, France, 1999.
- [41] A.K. Jain, M.N. Murty, and P.J. Flynn. Data clustering : A review. *ACM Computing Surveys*, 31(8) :1437–1443, 1999.
- [42] M. Larsen. Individual tree top position estimation by template voting., Juin 1999. Proc. of the Fourth International Airborne Remote Sensing Conference and Exhibition, volume 2, pages 83.90, Ottawa, Ontario.
- [43] M. Larsen and M. Rudemo. Using ray-traced templates to find individual trees in aerial photographs., 1997. Proc. of the 10th Scandinavian Conference on Image Analysis, volume 2, pages 1007-1014, Lappeenranta, Finlande.
- [44] J. Mangin. *Mise en correspondance d'images médicales 3D multi-modalités multi-individus pour la corrélation anatomo-fonctionnelle cérébrale*. Thèse de Doctorat, École Nationale Supérieure des Télécommunications, Télécom Paris, France, 1995.
- [45] R. Marée. *Classification automatiques d'images par arbre de décision*. Thèse de Doctorat, Université de Liège, 2005.
- [46] P. M. Mather. *Computer Processing of Remotely-Sensed Images. An Introduction*. John Wiley and Sons, Chichester, Royaume Uni, 1987.
- [47] H. Middelkoop, J. W. Miltenburg, and N. J. Mulde. Knowledge engineering for image interpretation and classification : a trial run. *ITC Journal*, 1 :27–32, 1989.
- [48] A. Perchant. *Morphisme de graphes d'attributs flous pour la reconnaissance structurelle de scènes*. Thèse de Doctorat, l'École Nationale Supérieure des Télécommunications, Paris, France, 2000.
- [49] G. Perrin. *Etude du Couvert Forestier par Processus Ponctuels Marqués*. Thèse de Doctorat, École doctorale de Centrale, Paris, France, 2006.
- [50] G. Perrin, X. Décombes, and J. Zerubia. Evaluation des ressources forestières à l'aide de processus ponctuels marqués. Technical report, 2005.
- [51] O. Pony, X. Descombes, and J. Zerubia. Classification d'images satellitaires hyperspectrales en zone rurale et périurbaine. Technical report, 2000.

- [52] P. Poudiougo. Texture : Un état de l'art, 1988. Journées Télédiffusion Colloque et Séminaire, Edition O RSTOM : 167-177.
- [53] D.A. Pouliot, D.J. King, F.W. Bell, and D.G. Pitt. Automated tree crown detection and delineation in high-resolution digital camera imagery of coniferous forest. *Remote Sensing of Environment*, pages 322–334, 2002.
- [54] A. Puissant, D. Sheeren, C. Weber, C. Wemmert, and P. Gańczarski. Amélioration des connaissances sur l'environnement urbain : intérêt de l'intégration de règles dans les procédures de classification., 2006. Interactions Nature-Société, analyse et modèles. UMR6554 LETG, La Baule.
- [55] D.A. Randell, Z. Cui, and A.G. Cohn. A spatial logic based on regions and connection, Octobre 1992. In Proc. Int. Conf. on Principles of Knowledge Representation and Reasoning KR 1992, San Mateo, CA, USA.
- [56] J. Serra. *Mathematical morphology and Image Analysis*. Academic Press, Floride, États Unis, 1982.
- [57] E. H. Shortliffe and B. Buchanan. A model of inexact reasoning in medicine. *Mathematical Biosciences*, 23 :351–379, 1975.
- [58] A. K. Skidmore. An expert system classifies eucalypt forest types using thematic mapper data and a digital terrain model. *Photogrammetric Engineering and Remote Sensing*, 55(1) :133–146, 1989.
- [59] Y. Smara, N. Ouarab, S. Laama, and D. Cherifi. Techniques de fusion et de classification floue d'images satellitaires multi sources pour la caractérisation et le suivi de l'extension du tissu urbain de la région d'alger, December 2003. 2nd FIG Regional Conference, Marrakech, Morocco.
- [60] B. Solaiman, L. E. Leland, and F. T. Ulaby. Multisensor data fusion using fuzzy concepts : application to land-cover classification using ers-1/jers-1 sar composites. *IEEE Trans. Geoscience and Remote Sensing*, 37(3) :1316–1326, 1999.
- [61] M. Sonka, S. K. Tadikonda, and S. M. Collins. Knowledge-based interpretation of mr brain images. *IEEE Trans. Medical Imaging*, 15(4) :443–451, 1996.
- [62] H. Suzuki. *Exploitation de connaissances structurelles en classification d'images : une approche par partition flou et optimisation combinatoire*. Thèse de Doctorat, Université Paul Sabatier, Toulouse, France, 2002.
- [63] G. Thibault, C. Devic, B. Fertil, J.L. Mari, and J. Sequeira. Indices de formes : de la 2d vers la 3d application au classement de noyaux de cellules. Technical report, 2007.

- [64] A.C. Varzi. Parts, wholes and partwhole relations, the prospects of mereotopology. *Data and Knowledge Engineering*, 20 :259–286, 1996.
- [65] L.P.C. Verbeke, F.M.B. Van Coillie, and R.R. De Wulf. A directional variant of the local maximum filter for stand density estimation from ikonos imagery., 2005. Proc. of ForestSat 2005, Boras, Suède.
- [66] L. Vieu. Spatial representation and reasoning in artificial intelligence., 1997. In O. Stock, éditeur, *Spatial and Temporal Reasoning*, Dordrecht, Kluwer.
- [67] C. Wemmert. *Classification hybride distribuée par collaboration de méthodes non supervisées*. Thèse de Doctorat, Université de Strasbourg 1, Strasbourg, France, 2000.
- [68] J. K. Wu, D. S. Cheng, W. T. Wand, and D. L. Cai. Model based remotely sensed imagery interpretation. *Int. J. Remote Sensing*, 9(8) :1347–1356, 1988.
- [69] M. Zehana. *Connaissances Structurelles et Interprétation d’Images Satellitaires*. Thèse de Doctorat, Université Paul Sabatier, Toulouse, France, 1995.
- [70] J. Zurada. *Introduction to Artificial Neural Systems*. West Publishing Co, St. Paul, Minnesota, États Unis, 1992.



# Intégration des informations et des connaissances structurelles dans la classification des images satellitaires forestières haute résolution

## **Résumé :**

Ce mastère présente une approche de classification qui intègre les informations et les connaissances structurelles dans l'interprétation automatique des images satellitaires forestières haute résolution. Nous avons procédé à travers trois phases de traitement. La première phase est une segmentation utilisant l'algorithme de croissance de région par mouvement brownien pour l'extraction des couronnes d'arbres. La deuxième phase est une caractérisation des régions basée sur les mesures et les indices de formes. La troisième est une phase d'apprentissage consacrée à la définition des classes dans la zone d'étude et une classification supervisée permettant d'affecter chaque région de l'image. Une étude expérimentale sur une image QuickBird nous a permis d'évaluer l'efficacité de notre système.

**Mots clefs :** Classification, informations structurelles, segmentation, indice de formes, images forestière haute résolution.

## **تلخيص:**

يقدم هذا الماجستير منهجية تصنيف تدمج المعلومات والمعارف الهيكلية في التفسير الآلي لصور الغابات الرقمية عالية الدقة. تتكون هذه المنهجية من ثلاثة مراحل. تتمثل المرحلة الأولى في تجزئة للصور إلى مجموعة من تيجان الشجر باستخدام خوارزمية تنمية المناطق بالحركة البراونية. المرحلة الثانية هي تحديد خصائص المناطق استنادا على القياسات و المؤشرات الأشكال. المرحلة الثالثة هي مرحلة تمرين و تصنيف آلي يعتمدان على الخصائص المقتطفة في المرحلة الثانية. لتقييم هذا العمل قمنا بمجموعة من الاختبارات على صورة من نوع "QuickBird"

**كلمات المفاتيح:** تصنيف، المعلومات الهيكلية، تجزئة، مؤشرات الأشكال، صور الغابات الرقمية عالية الدقة

## **Abstract :**

This master introduces an approach of classification which integrates structural knowledge and information in automatic interpretation of the high forest satellite image. We proceed through three phases. The first phase is a segmentation using the region growing by Brownian motion algorithm for the extraction of the tree crowns. The second phase is the region characterization based on measures and shape indices. The third is a phase of training devoted to the definition of the classes in the study zone and a supervised classification allowing the assignment of each region of the image. An experimental study on a QuickBird image enabled us to evaluate the effectiveness of our system.

**Key words:** Classification, structural information, segmentation, shape indexes, measures.